# Processus d'annotation sémantique

# pour favoriser l'interopérabilité autour des données de biodiversité au sein de l'infrastructure AnaEE-France

*R. Yahiaoui*
*D. Maurice*
*A. Schellenberger*

# Intro

– Infrastructure nationale “Analyse et Expérimentation sur les Écosystèmes

– Offre à la communauté scientifique des plateformes d’expérimentation, de modélisation et des BDD ( dont celles des  SOERE )

– Mettre en place une **interopérabilité** basée sur les technos du **web sémantique**

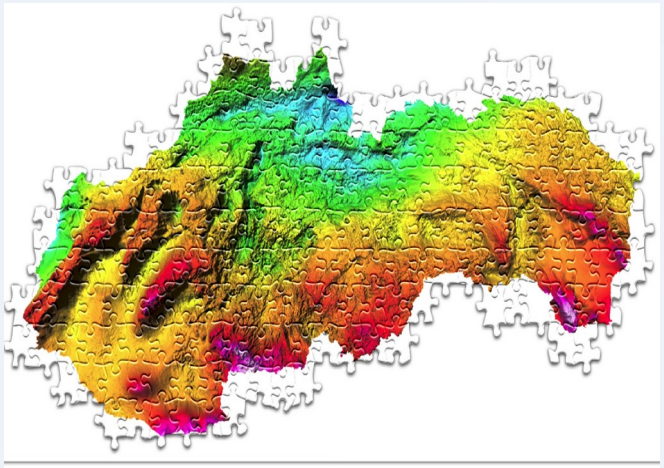

Hétérogénéité

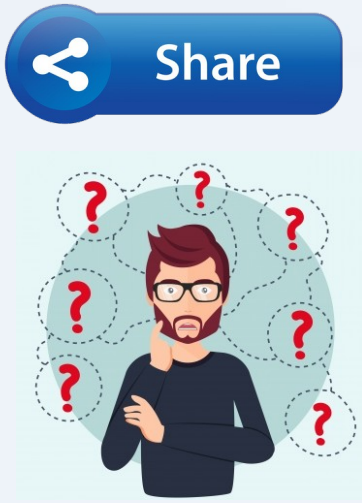


Défi

Automatisation

Et c'est justement ce qui fera l'objet de cette présentation...

# Processus d'annotation et production de données sémantiques

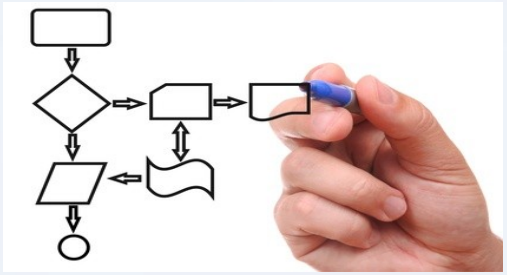

Définitions ✓
Architecture Générale ✓
Démarche suivie ✓

Aspects Fonctionnels ✓
~~Algorithme~~ / ~~Code~~ ✗

W3C® Semantic Web

Le **Web sémantique**, ou toile sémantique, est un mouvement collaboratif mené par le World Wide Web Consortium (W3C) qui favorise des méthodes communes pour échanger des données sur Internet pour accéder simplement.. ( Wikipedia )

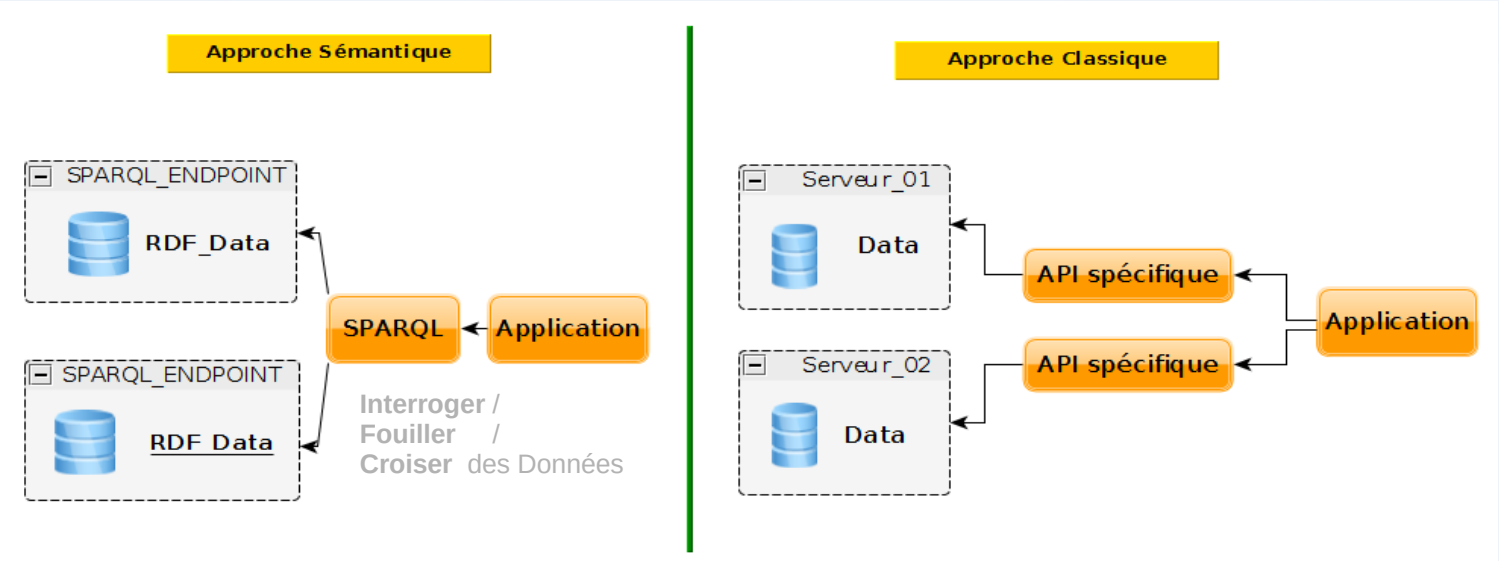

# Pile de Standardisation

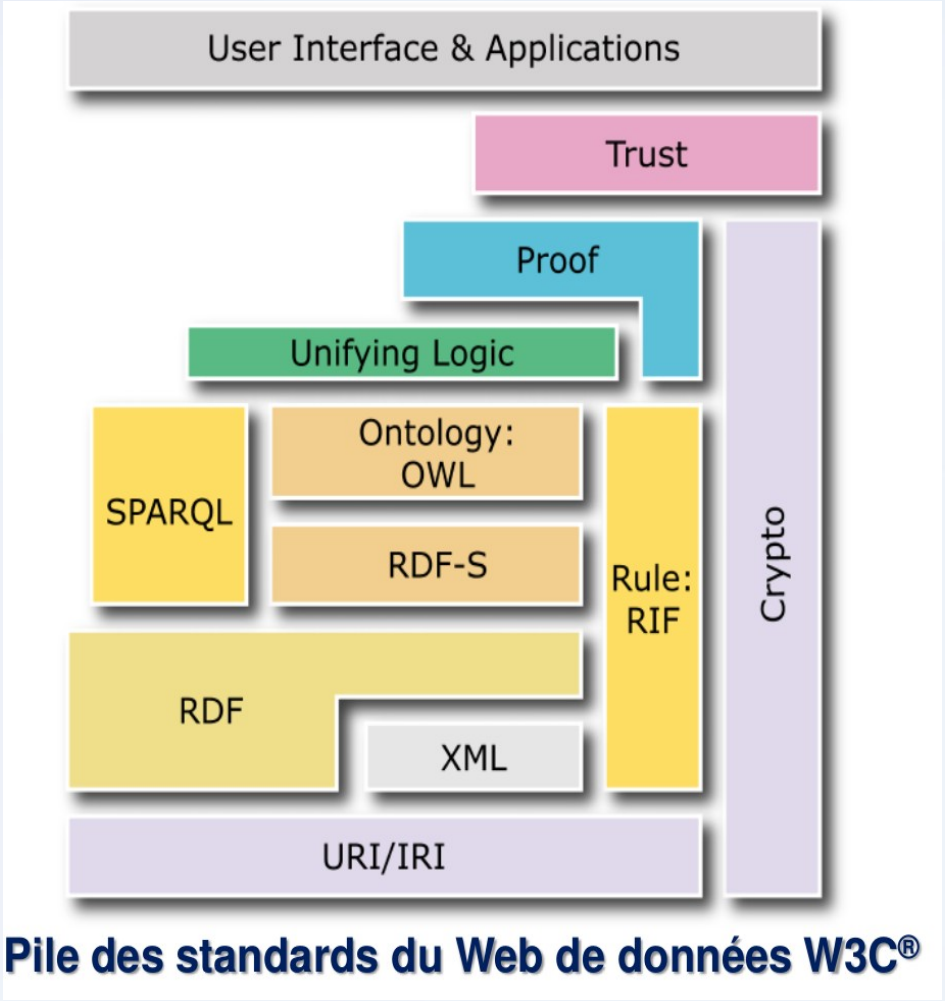


Pile des standards du Web de données W3C®

# Pile de Standardisation

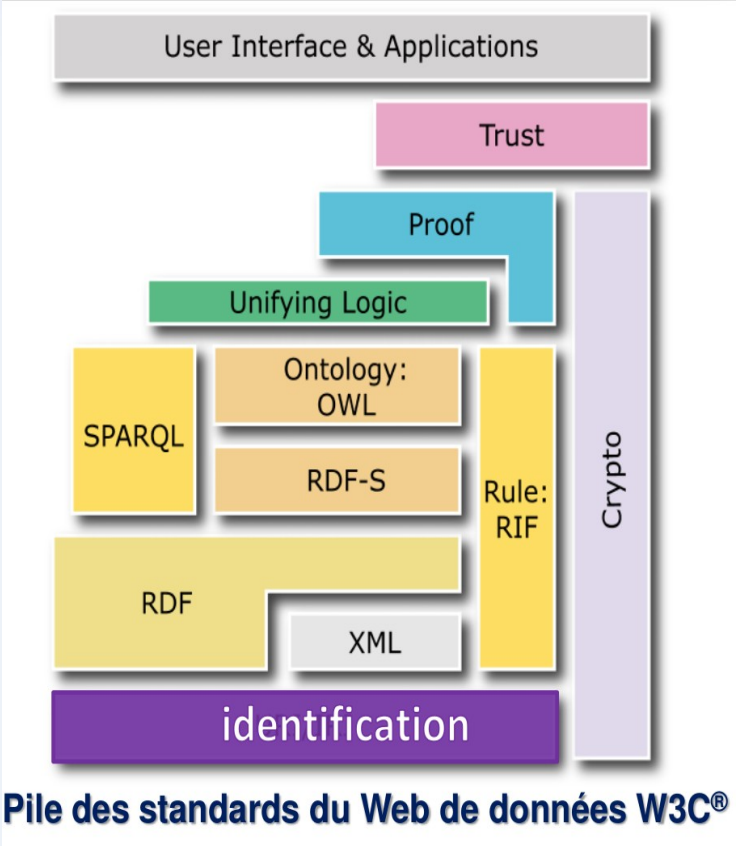

Pile des standards du Web de données W3C®

## Identification (**URI – IRI** ) :

Identifier n'importe quel objet du monde sur le web

## Exemple :

http://dbpedia.org/page/**Napoleon**

http://dbpedia.org/resource/**Montreal**

http://dbpedia.org/page/**Moon**

# Pile de Standardisation

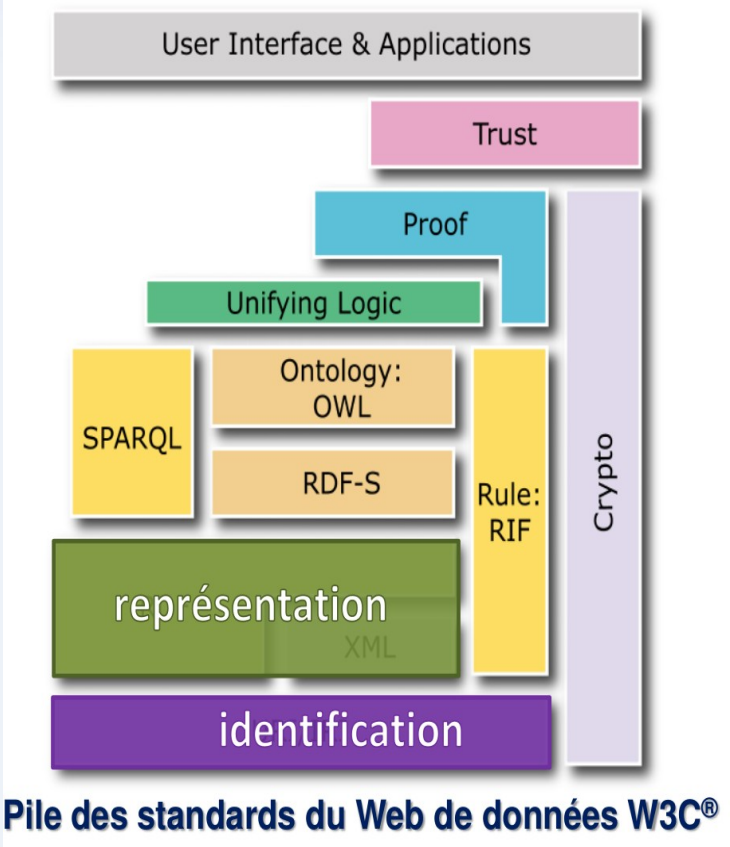


Pile des standards du Web de données W3C®

**RDF** Moyen pour représenter les ressources

**R**esource ( tout ce qui peut avoir un URI. n'importe-quel objet du monde )

**D**escription ( associer aux URI des descriptions structurées ( caractéristiques ) directement utilisable dans nos applications

**F**ramework ( Modèle et syntaxe pour échanger ces descriptions sur le web )

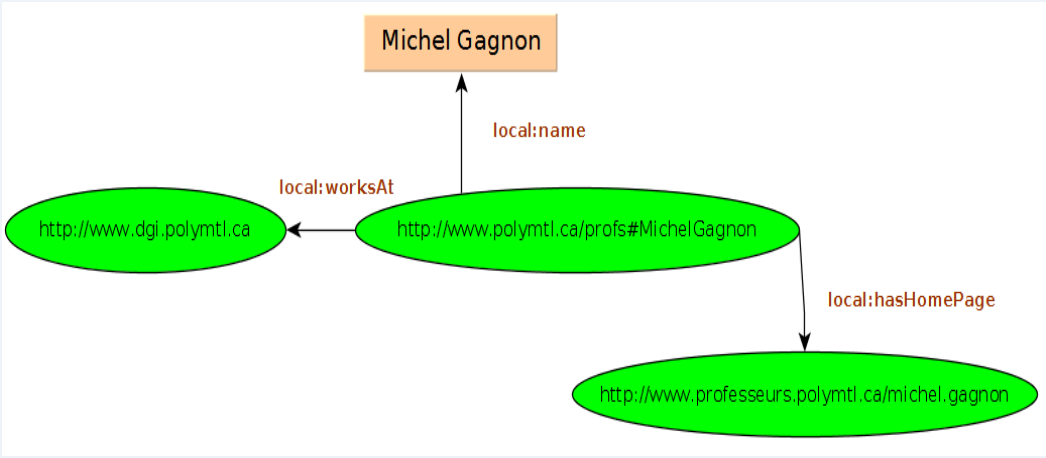

# Pile de Standardisation

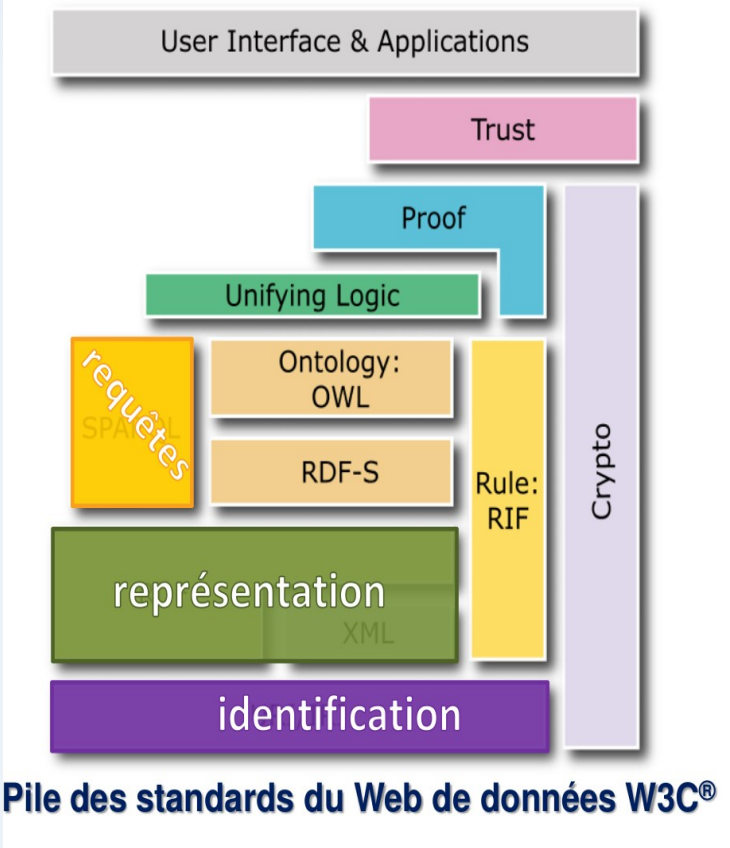


Pile des standards du Web de données W3C®

## SPARQL

SPARQL Protocol and RDF Query Language

**Interroger** / **Fouiller** / **Croiser** des Données

```
SELECT ?s ?p ?o
 WHERE    {
   ?s ?p ?o .
 }
```

# Pile de Standardisation

Échanger les schémas des données et raisonner sur ces données

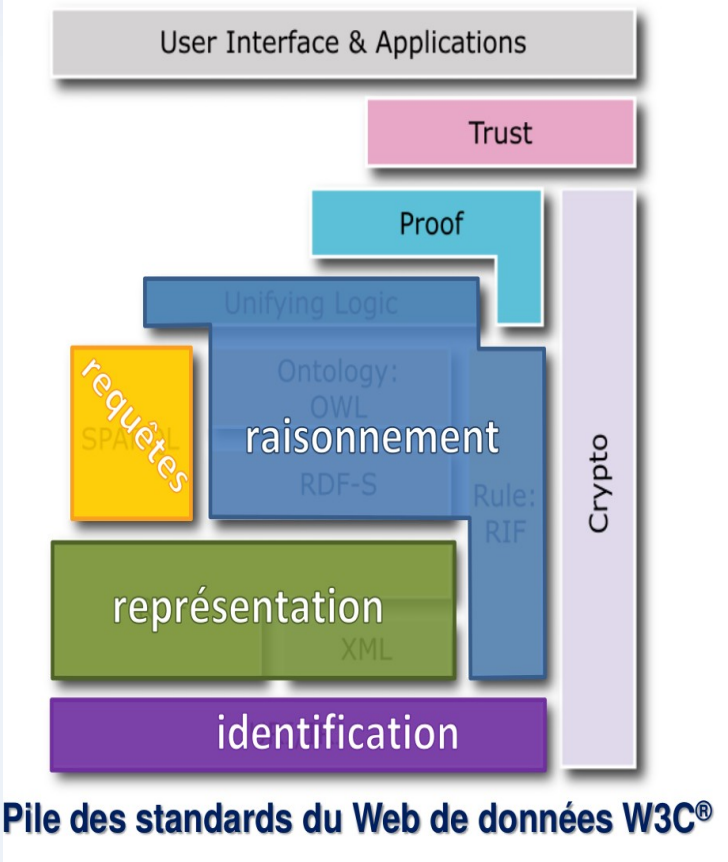


Pile des standards du Web de données W3C®

## RDFS **Vocabulaire** pour décrire des ontologies légères

Langage de description des vocabulaires RDF

rdfs:subClassOf - rdfs:domain - rdfs:range

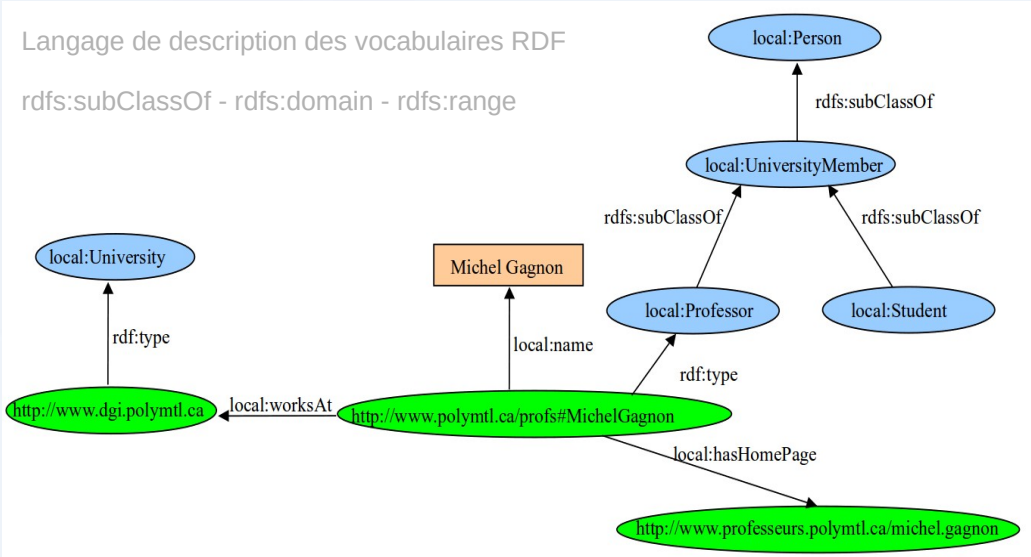


## OWL **Vocabulaire** pour décrire des ontologies plus poussées

Un père est un homme qui a au moins un enfant

( MINACARDINALITY ... )

# Pile de Standardisation

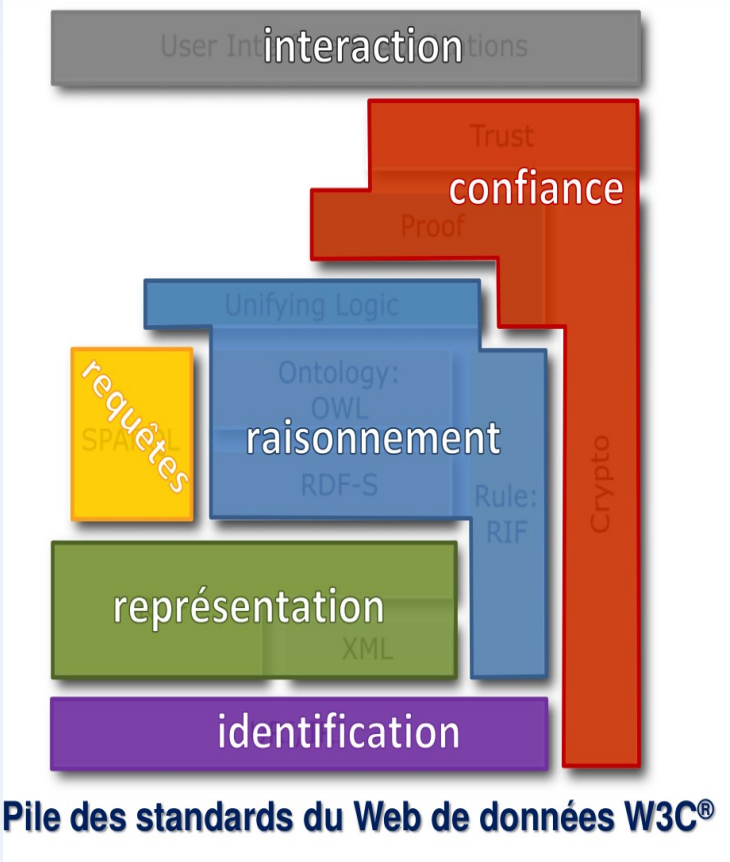

Pile des standards du Web de données W3C®

Travaux en cours

## Confiance ( Trust et Proof ) :

Faire de la traçabilité et une vérification sur les données afin de les valider.

## Interaction ( User Interface ) :

Faciliter l'interaction des utilisateurs avec les données

# Ontologie

Une Ontologie est un **réseau sémantique** regroupant un ensemble de **concepts décrivant un domaine**. Ces concepts sont **liés les aux autres** par des relations hiérarchiques d'une part, et sémantiques d'autres part.

Restriction, cardinalité des propriétés, symétrie, transitivité, inversement fonctionnel, intersection, union, disjonctions....

# Thésaurus

Liste structurée et hiérarchisée des termes d'un domaine du savoir plus ou moins large. Chacun des mots est relié à d'autres par divers types de relations hiérarchiques et/ou associatives

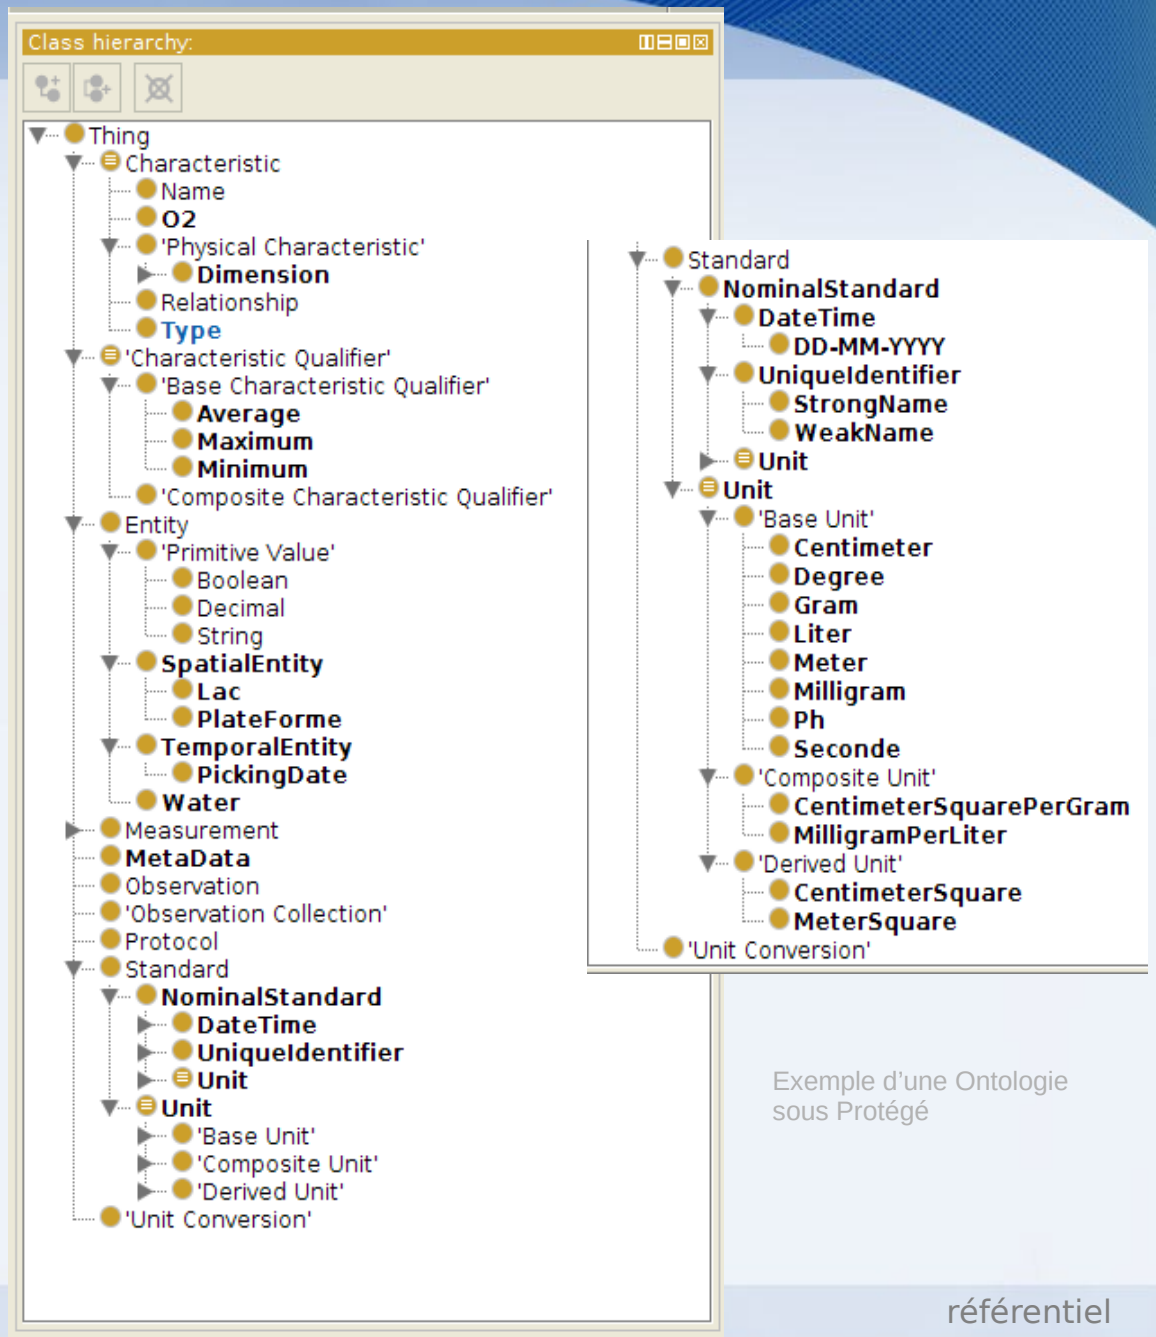


Exemple d'une Ontologie sous Protégé

# Schéma d’architecture Générale

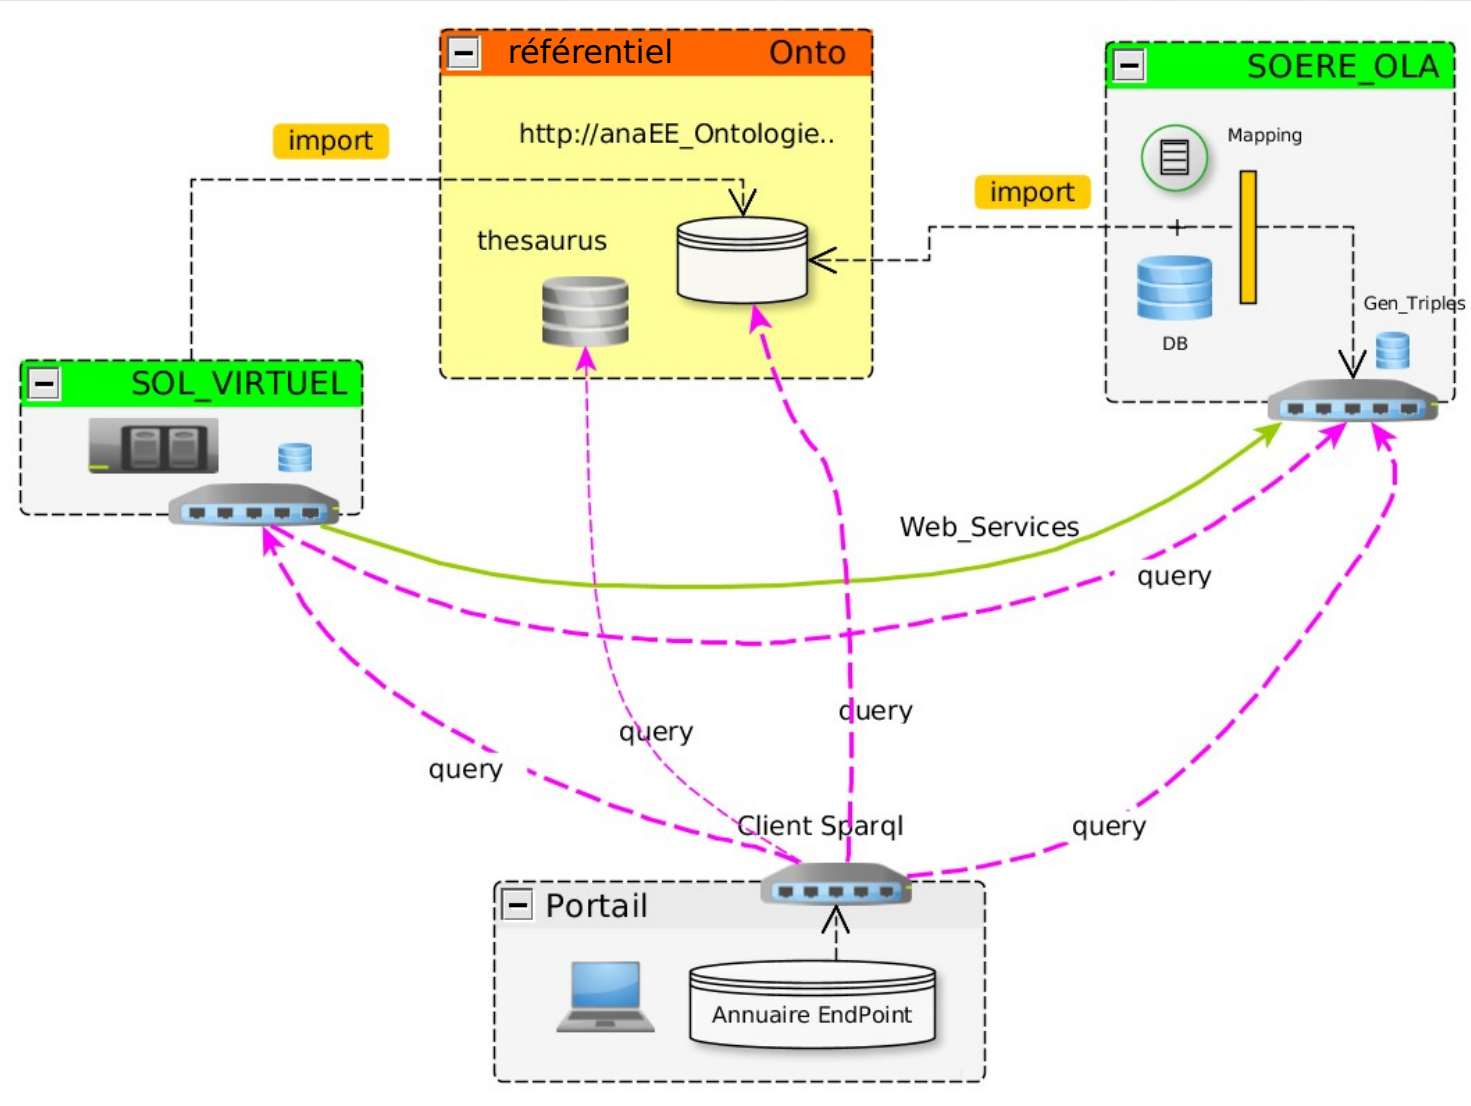


Pour faire cela, chaque S.I s’est appuyé une démarche particulière

# Mise en place de l'interopérabilité – AnaEE-F

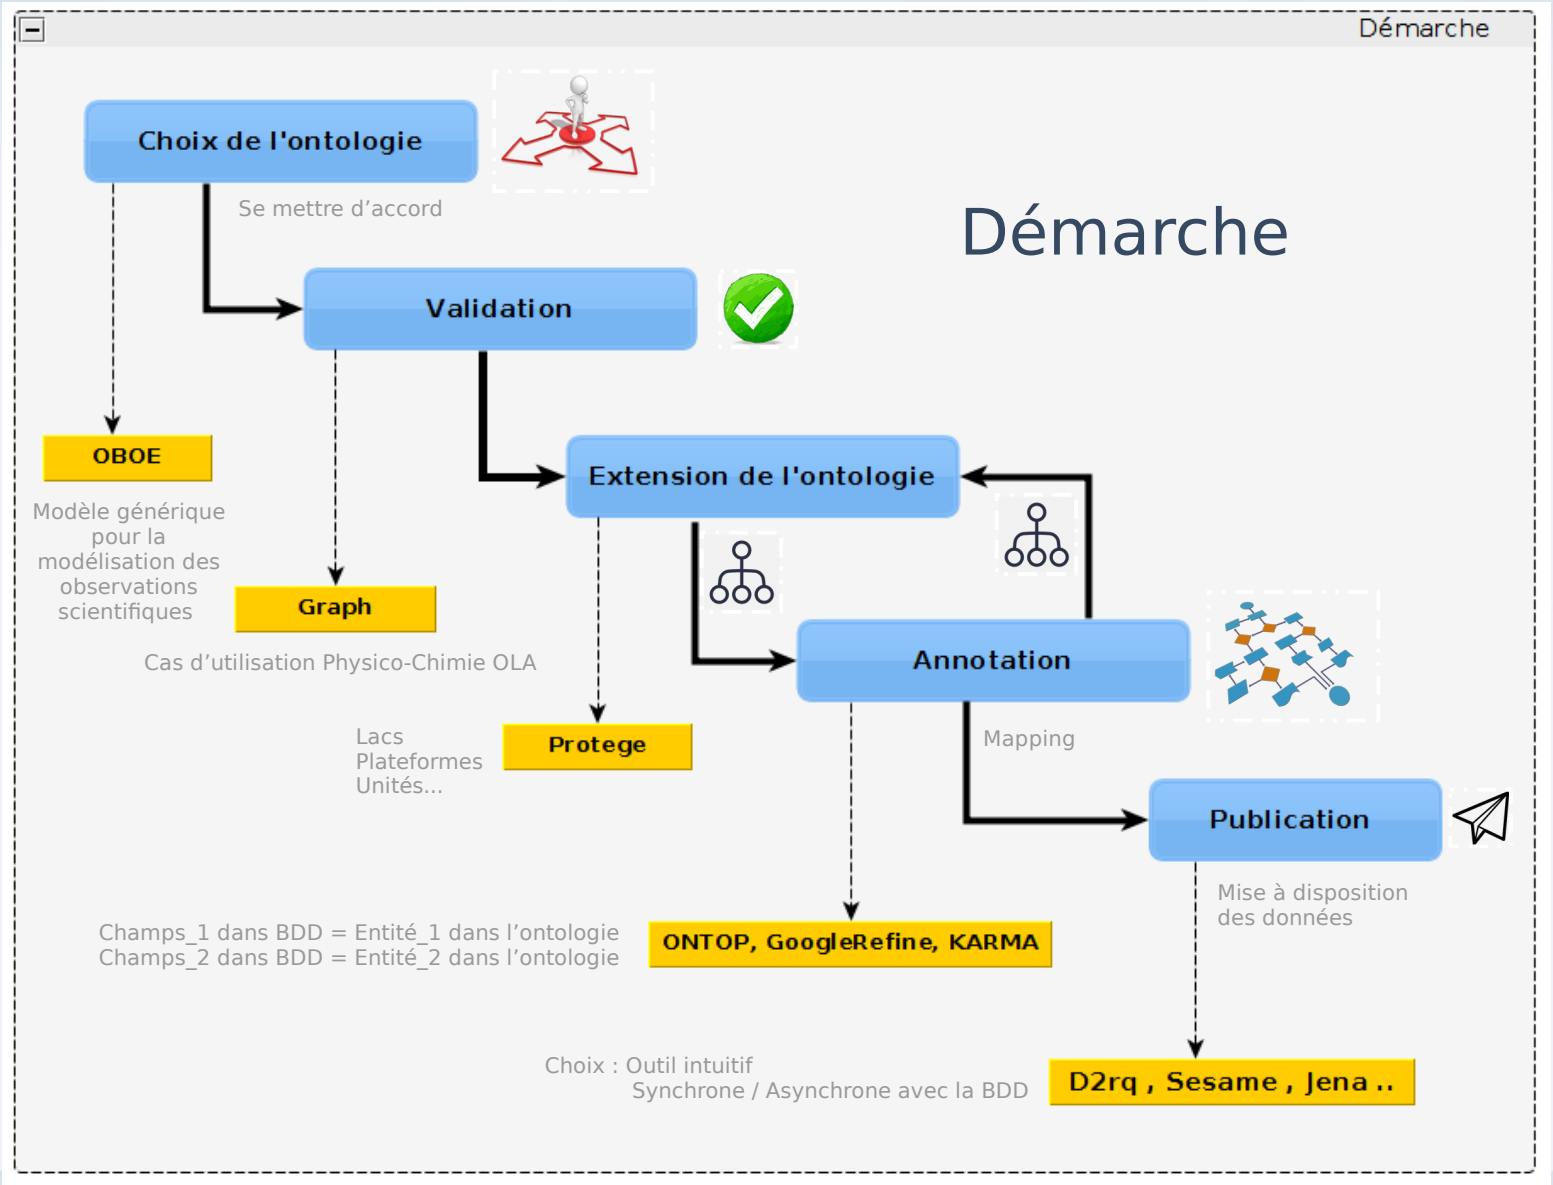

# Choix de l’Ontologie

## OBOE

Ontologie conçue comme étant un modèle générique pour la modélisation et la représentation des observations scientifiques

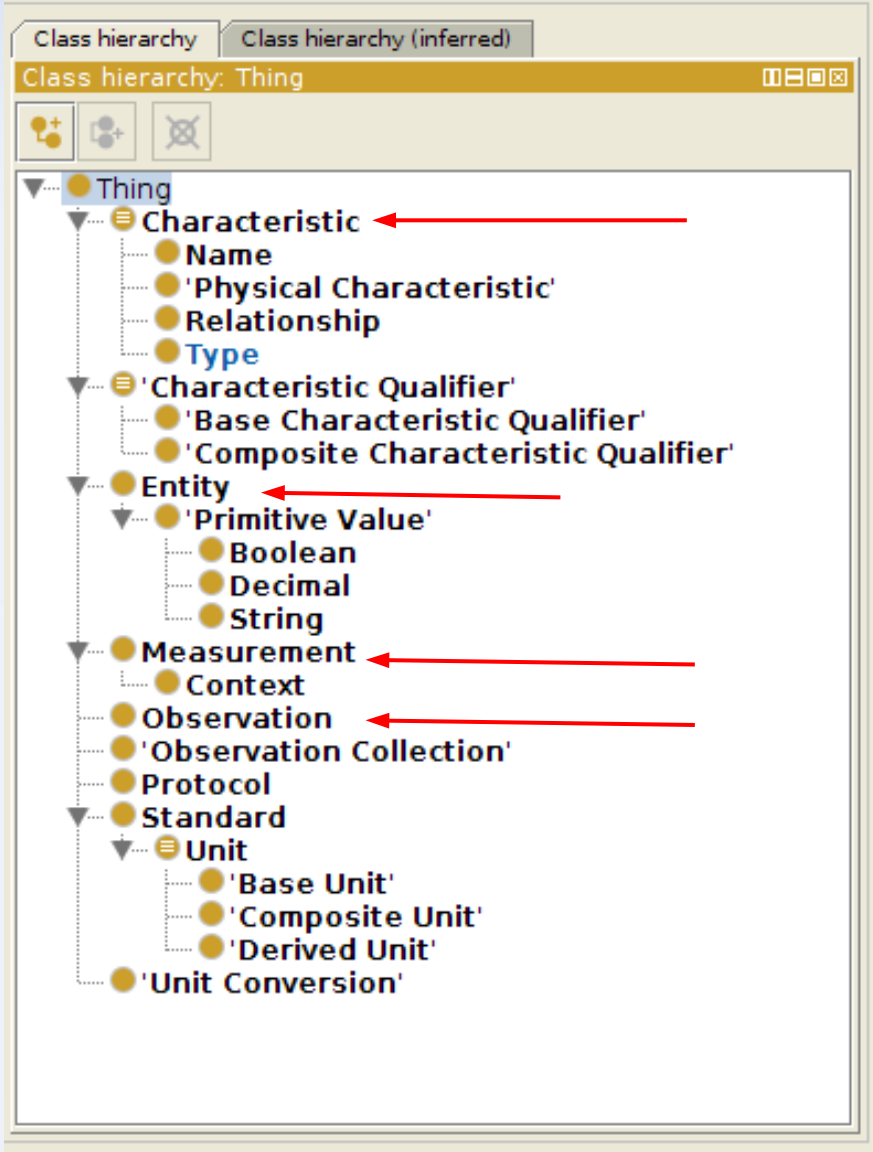

## Schéma : Cas **Physico-Chimie** du SOERE **OLA**

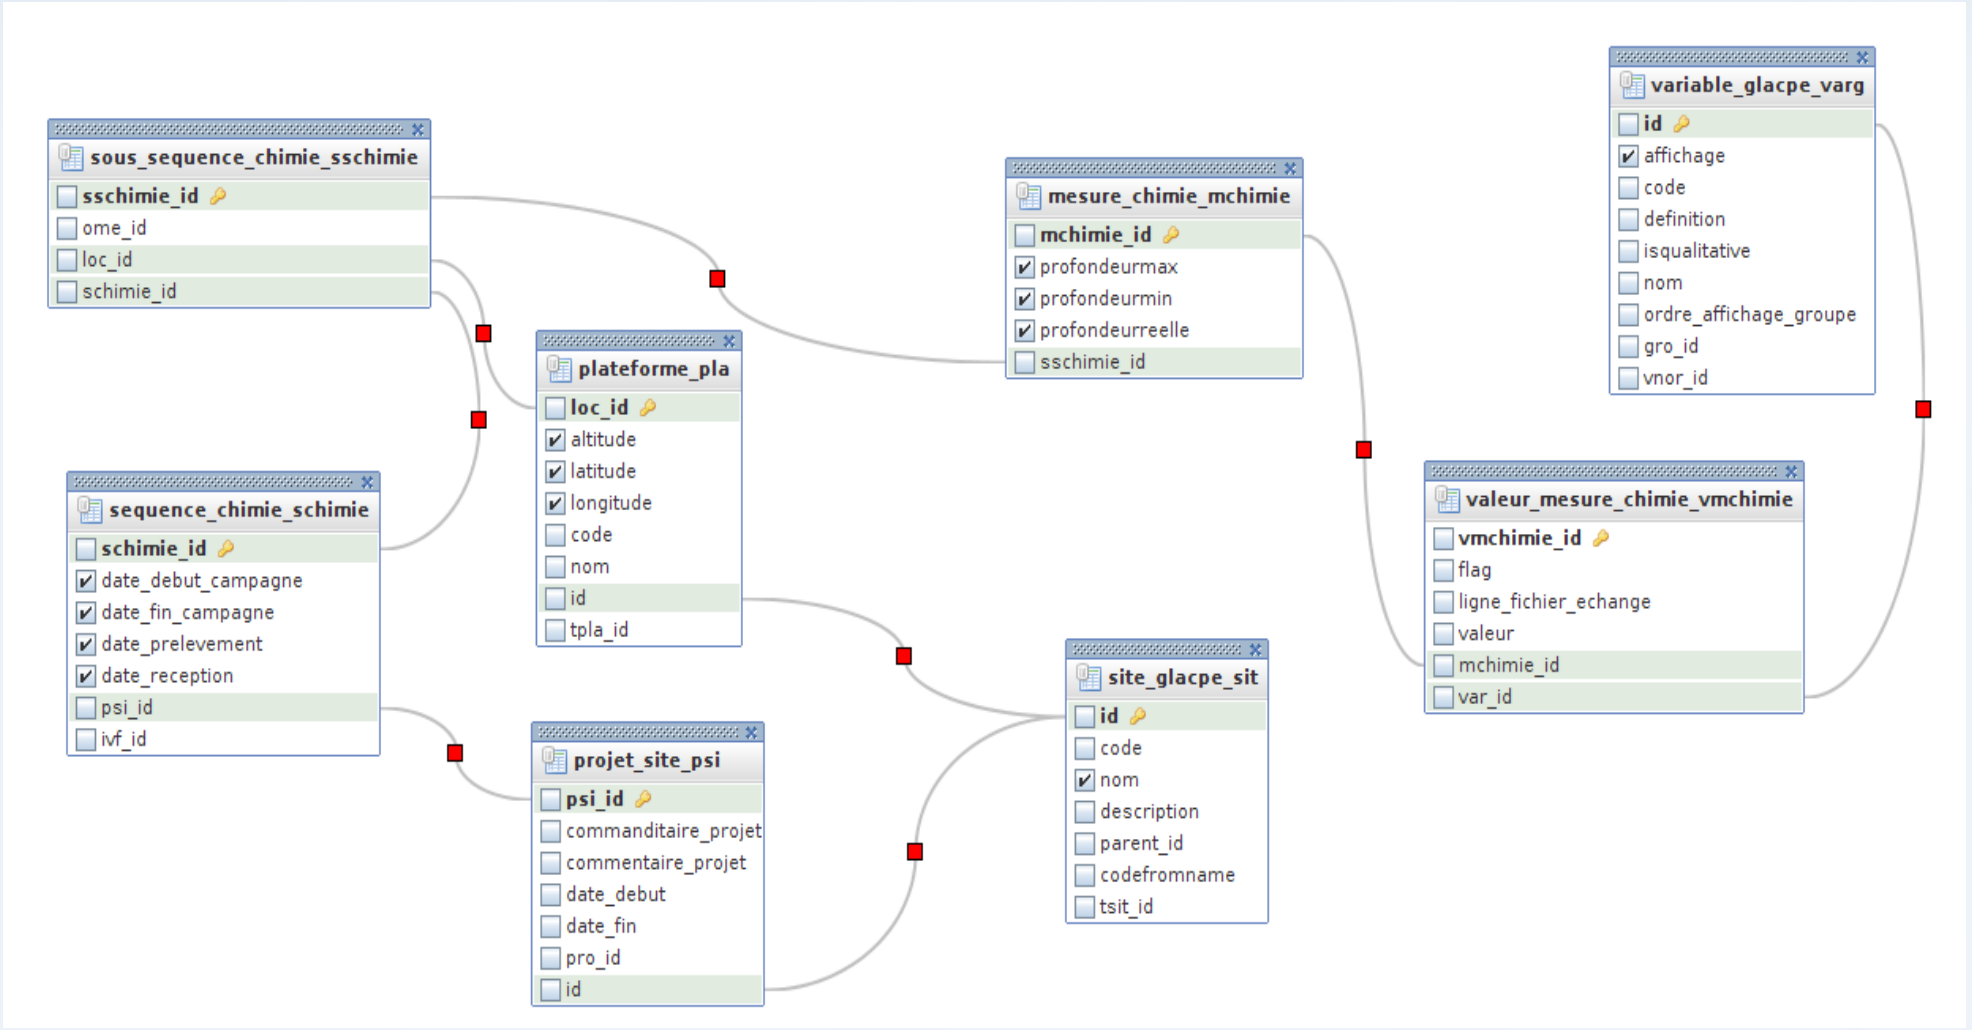

# Données SOERE OLA

| | A | D | E | F | G | H | I | J | K | L |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | | | | | | | | | | |
| 2 | | MG/L | MG/L | MG/L | MG/L | MG/L | MG/L | MG/L | MG/L | MG |
| 3 | | Na | K | SO4 | Cl | Al | Ba | Fe | Li | M |
| 28 | BKY | 1,7 | 1,0 | 9,30 | 2,64 | 0,990 | 0,0341 | 1,130 | 0,0030 | 0,02 |
| 29 | BKZ | 232,0 | 10,8 | 68,70 | 404,00 | 0,110 | 0,0303 | 0,644 | 0,0140 | 0,14 |
| 30 | BKAA | 3,3 | 0,3 | 2,20 | 12,20 | 0,020 | 0,0181 | 0,230 | **0,0005** | 0,02 |
| 31 | BKAB | 2,7 | 0,7 | **0,10** | 8,46 | 0,010 | 0,0292 | 0,068 | 0,0010 | 0,0 |
| 32 | BKAC | 22,1 | 3,1 | 13,40 | 72,80 | 1,230 | 0,1250 | 4,940 | 0,0090 | 0,2 |
| 33 | BKAD | 1,9 | 0,7 | 34,40 | 3,91 | 0,220 | 0,0159 | 0,508 | 0,0020 | 0,0 |
| 34 | BKAE | 3,5 | 0,5 | 32,90 | 17,10 | 0,010 | 0,0139 | 0,049 | **0,0005** | 0,00 |
| 35 | | 0,9 | 0,3 | 5,00 | 2,52 | **0,005** | 0,0126 | 0,034 | 0,0010 | 0,00 |
| 36 | BKAG | 1,1 | 0,2 | 9,40 | 2,35 | 0,010 | 0,0103 | 0,075 | **0,0005** | 0,00 |
| 37 | BKAH | 0,4 | 0,3 | 1,60 | 0,84 | 0,010 | 0,0072 | 0,054 | **0,0005** | 0,02 |
| 38 | BKAI | 0,5 | 0,4 | 4,70 | 1,22 | 0,170 | 0,0061 | 0,304 | 0,0010 | 0,02 |

| | AA | AB | AC | AD | AE | AF | |
|---|---|---|---|---|---|---|---|
| | | uS | Celsius | m asl | | | L=Lake |
| | pH | COND | TEMP | ELEV | LAT | LONG | P=Pond |
| | 7,6 | 48,0 | 6,0 | 2 | 74 30.69N | 121 41.08W | L |
| | 8,1 | 1160,0 | 8,0 | 0 | 74 27.82N | 122 34.55W | P |
| | 7,6 | 83,0 | 5,0 | 8 | 74 21.46N | 124 33.92W | P |
| | 8,1 | 89,0 | 7,0 | 20 | 74 08.10N | 124 12.52W | P |
| | 8,4 | 333,0 | 8,0 | 0 | 72 21.13N | 125 24.43W | P |
| | 7,8 | 137,0 | 3,0 | 122 | 71 43.79N | 123 28.94W | L |
| | 8,4 | 216,0 | 7,5 | 169 | | | |
| | 7,8 | 109,0 | 3,5 | 175 | | | |
| | 7,9 | 105,0 | 8,0 | 105 | 72 39.96N | 119 56.11W | P |
| | 7,7 | 41,0 | 3,0 | 131 | 73 35.57N | 119 35.01W | L |
| | 7,9 | 65,0 | 4,0 | 137 | 73 20.79N | 116 46.23W | L |
| | 8,5 | 137,0 | 7,0 | 195 | 73 29. | 115 41.5W | P |

Site

Observation

PH

Measurement

Location

Oui mais.. pas suffisant !

# Graphe RDF 1/3

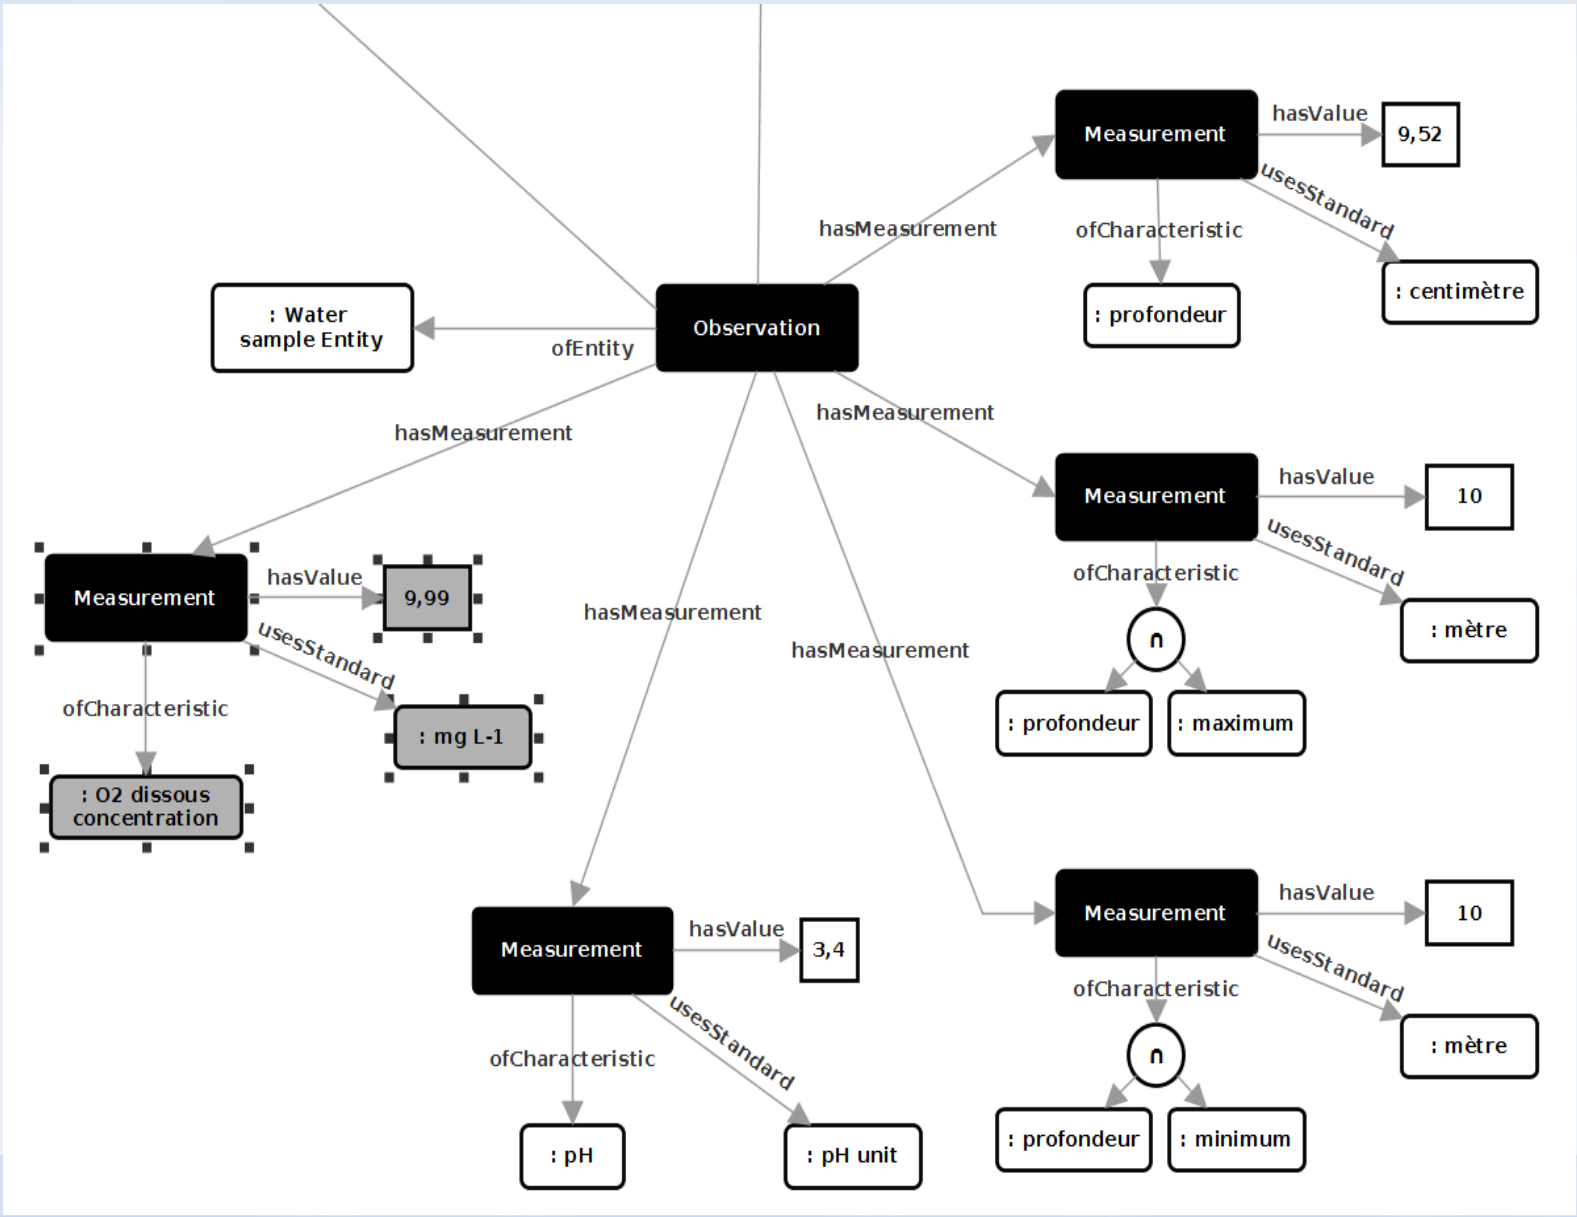

# Graphe RDF 2/3

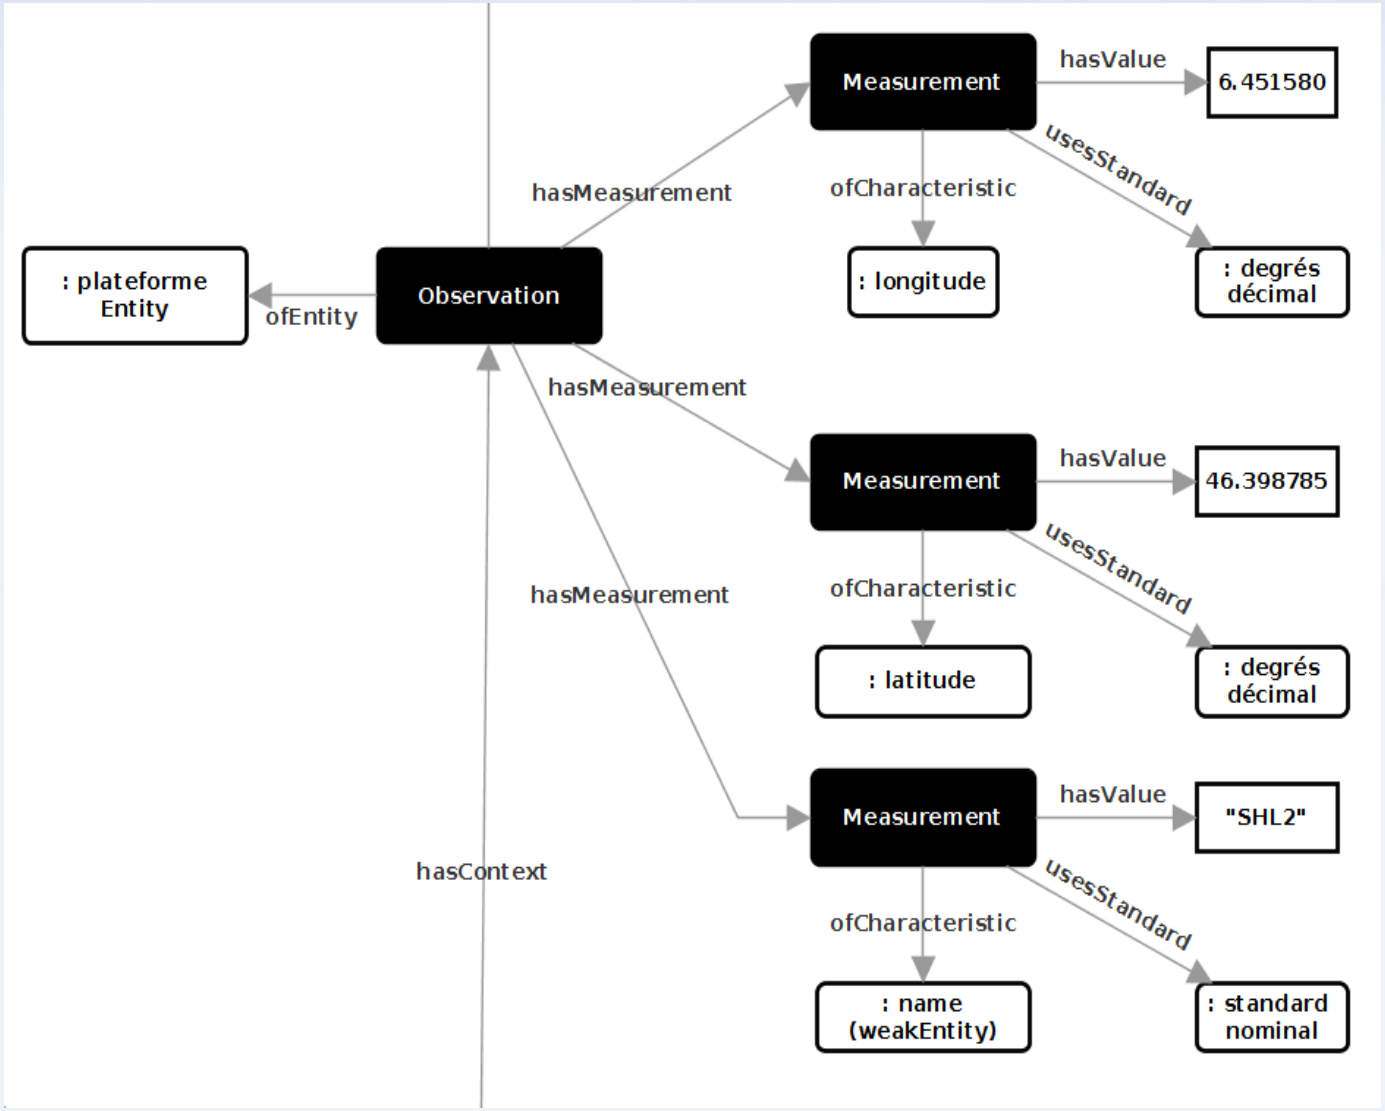

# Graphe RDF 3/3

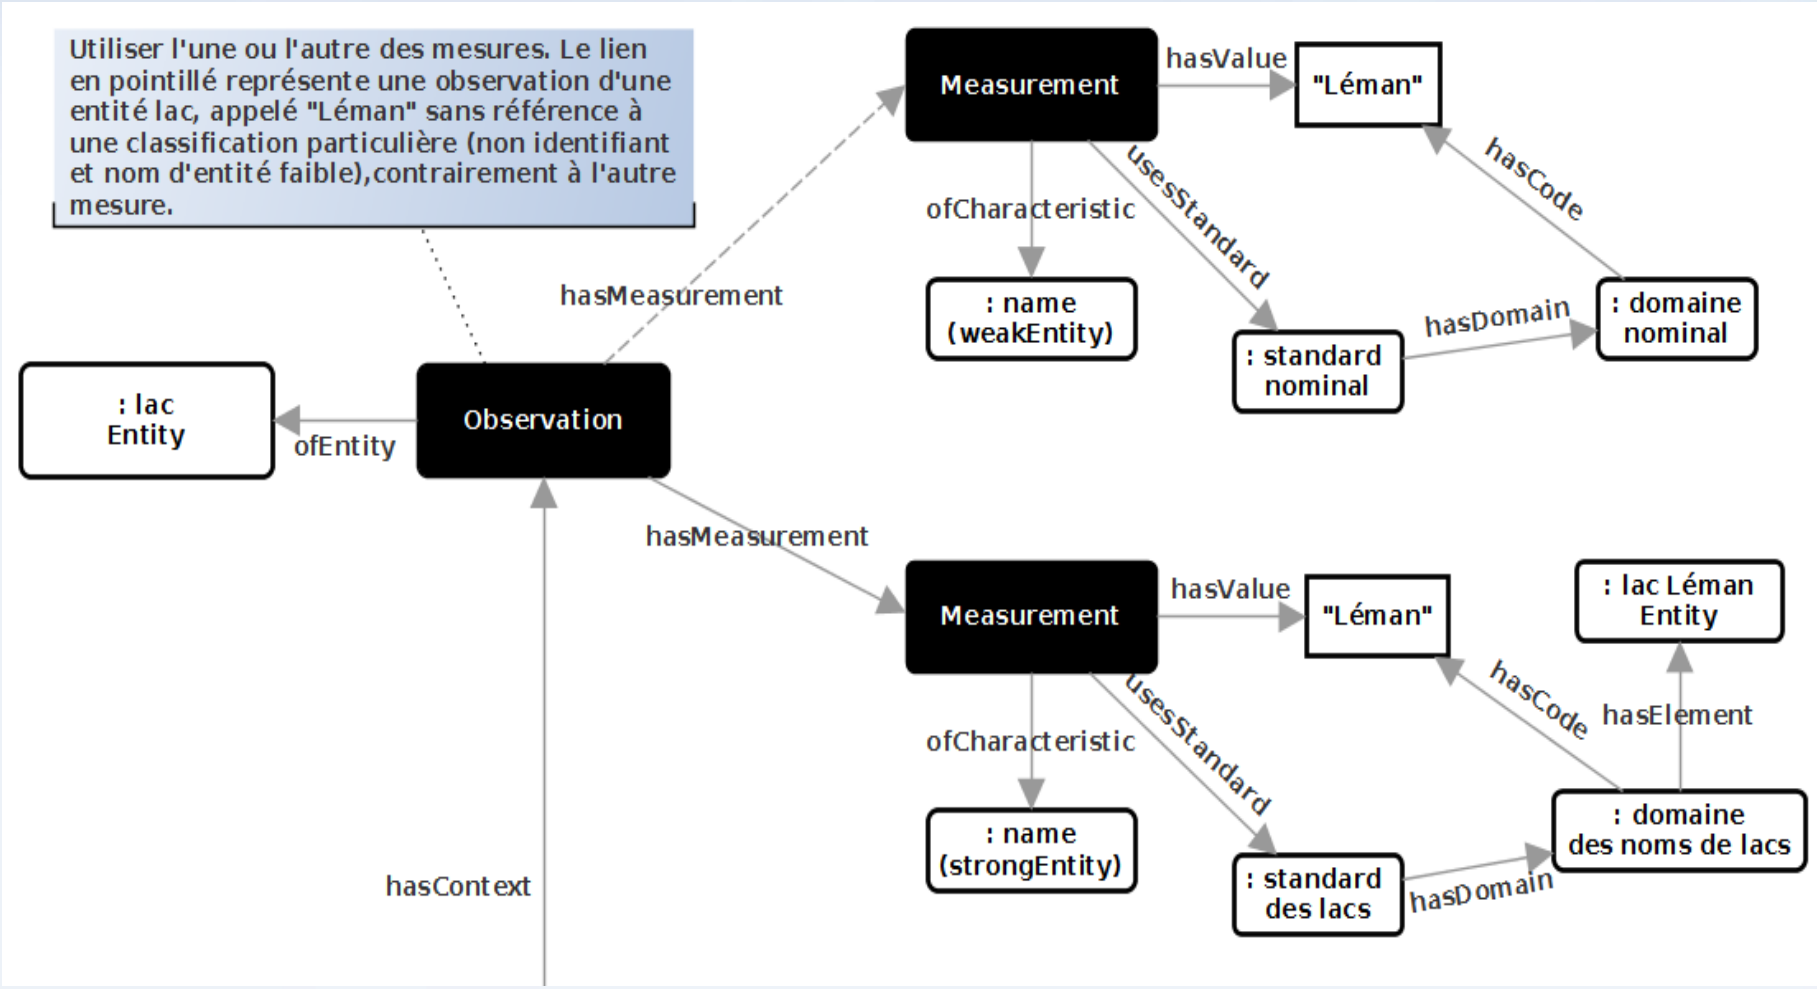


Validation

# Extension de l'Ontologie

**Extension** OBOE

OBOE-CORE

**+**

' Thésaurus '

**=**

**Ontologie AnaEE-F**

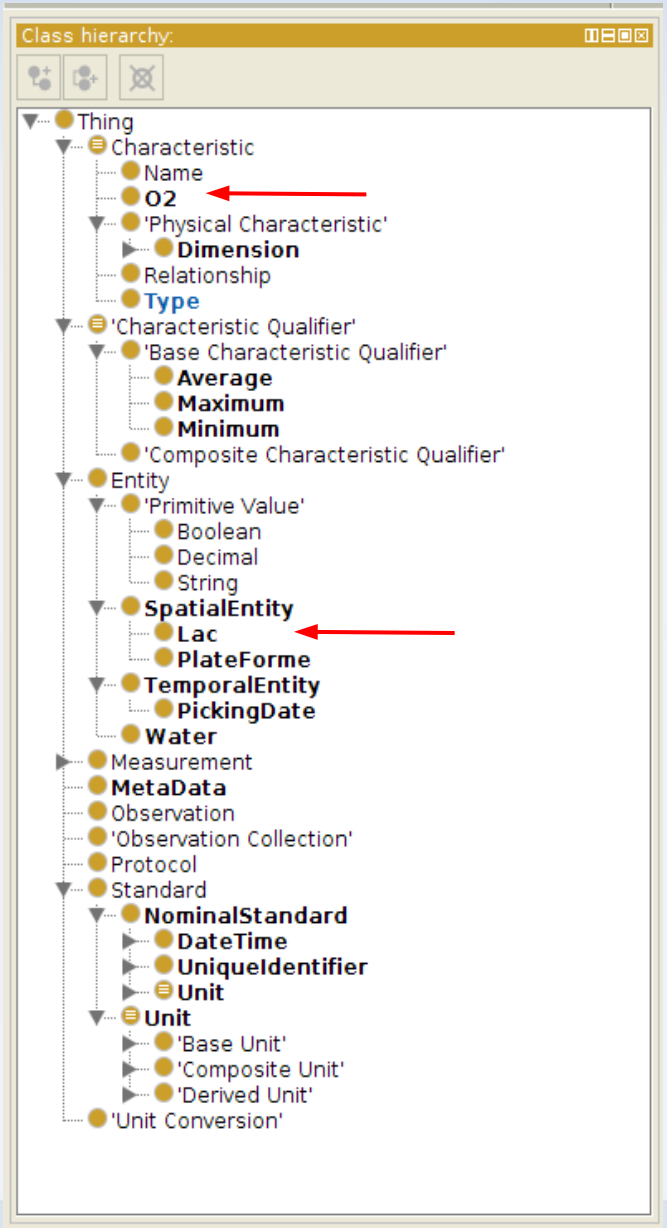


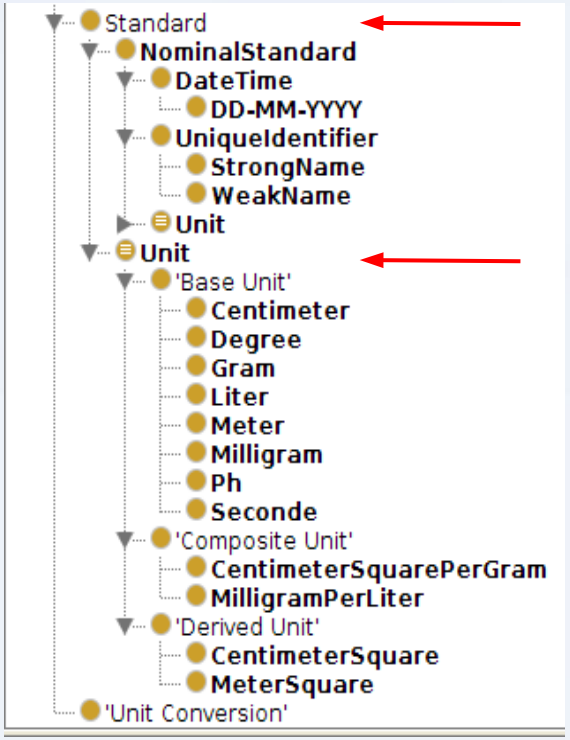

# [ Transformation RDB – RDF ( 1/2) ]



| Data | | |
|---|---|---|
| Nom | employeur | HomePage |
| MichelGagnon | poly | http://www.professeurs.polymtl.ca/michel.gagnon |

```
#s1   :Nom          "MichelGagnon"
#s1   :Employeur    "poly"
#s1   :HomePage     "http://www.professeurs.polymtl.ca/michel.gagnon"
```

Le Sujet représente la ressource ,
Le Prédicat représente une propriété applicable sur la ressource
L'objet représente une données ou une autre ressource

# Annotation [ Transformation RDB – RDF ( 2/2) ]

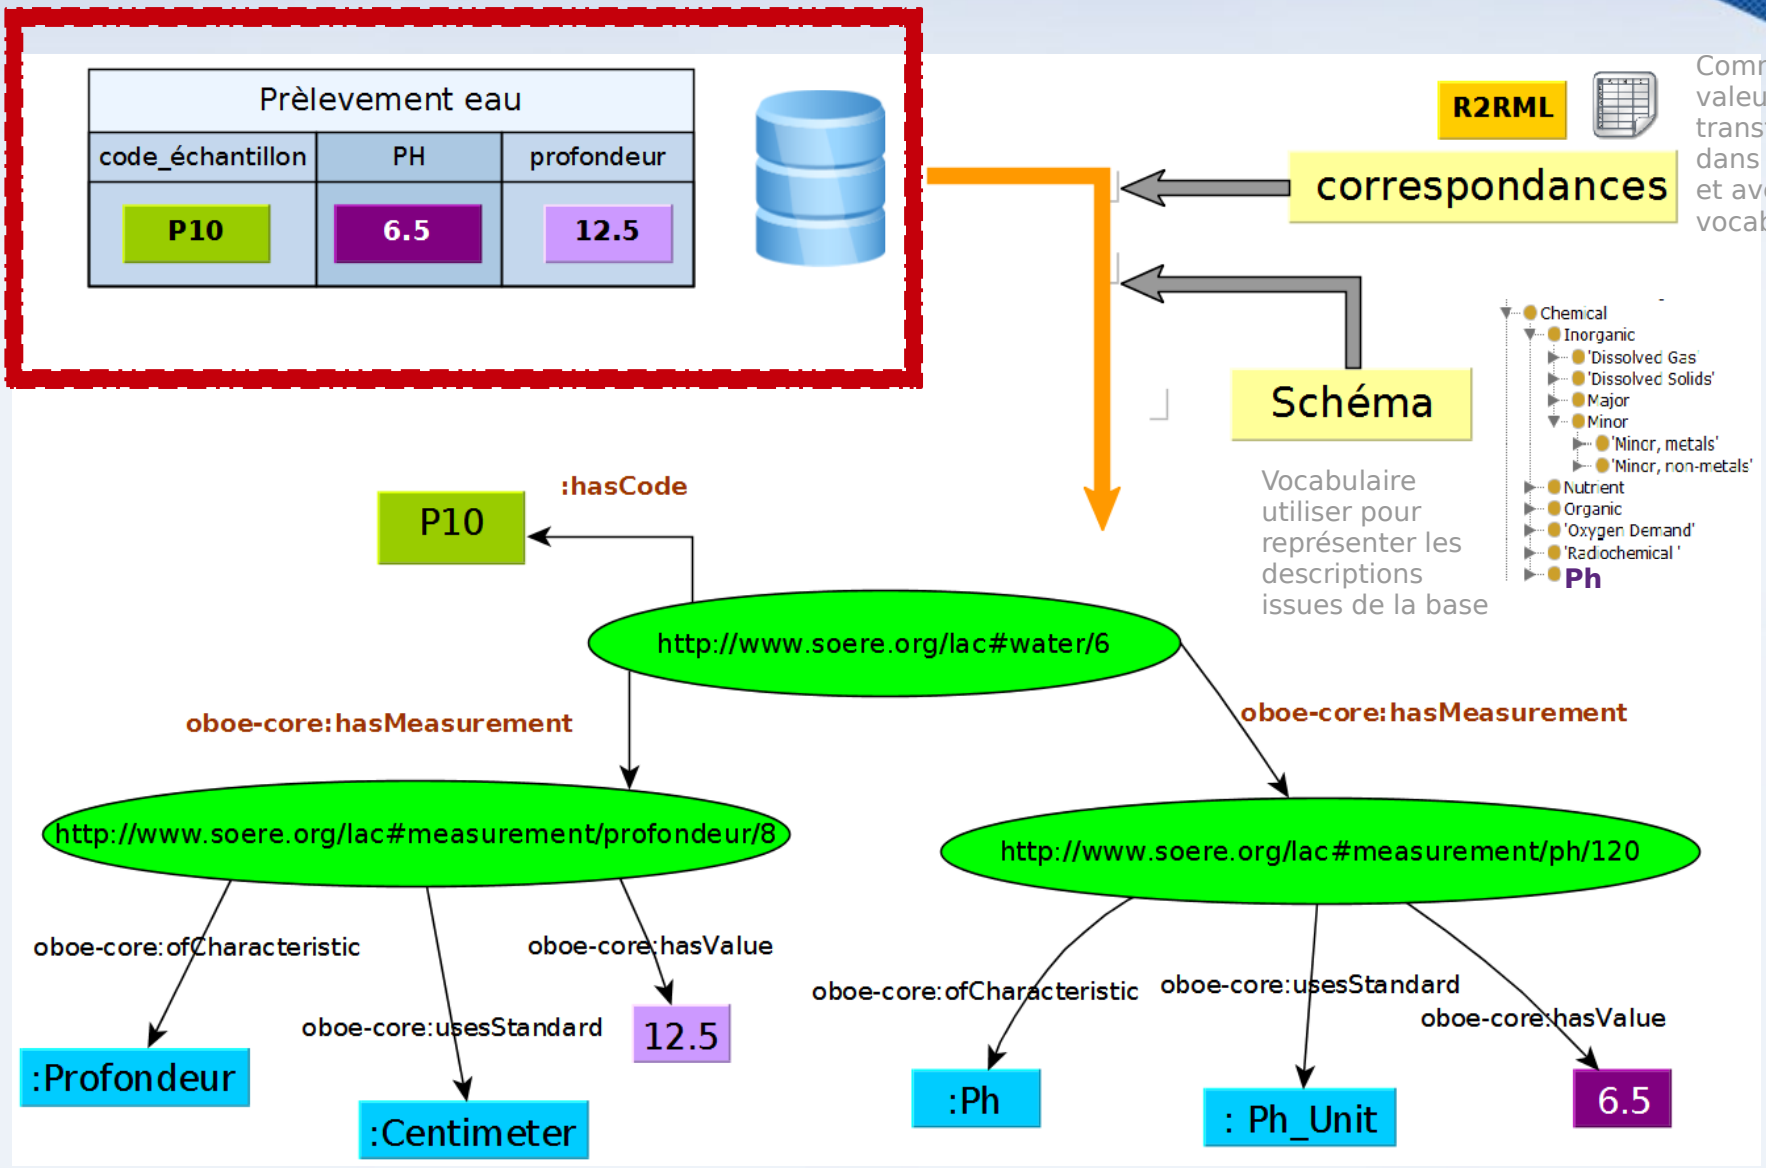

# Annotation [ Transformation RDB – RDF ( 2/2) ]

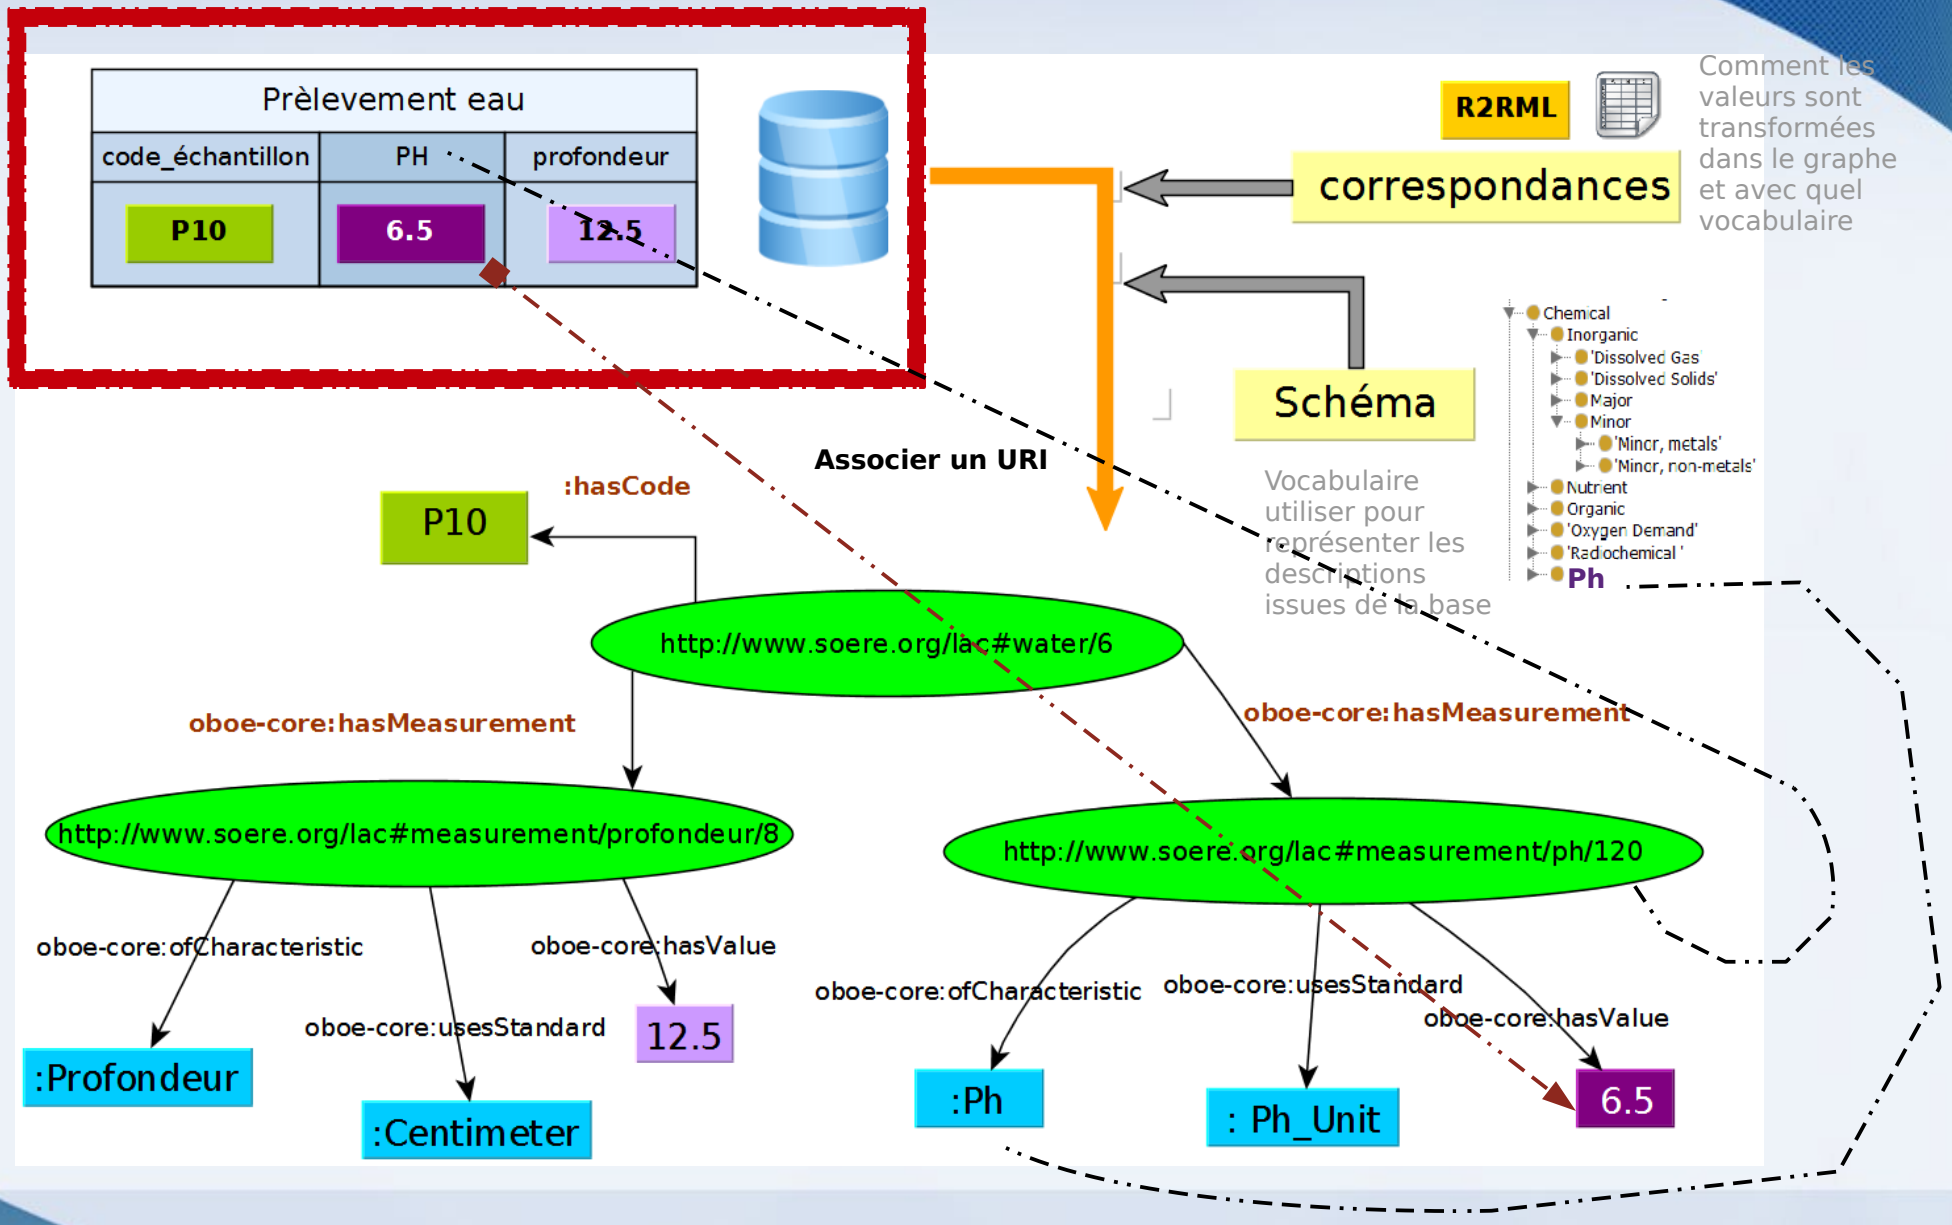

# Annotation [ Transformation RDB – RDF ( 2/2) ]

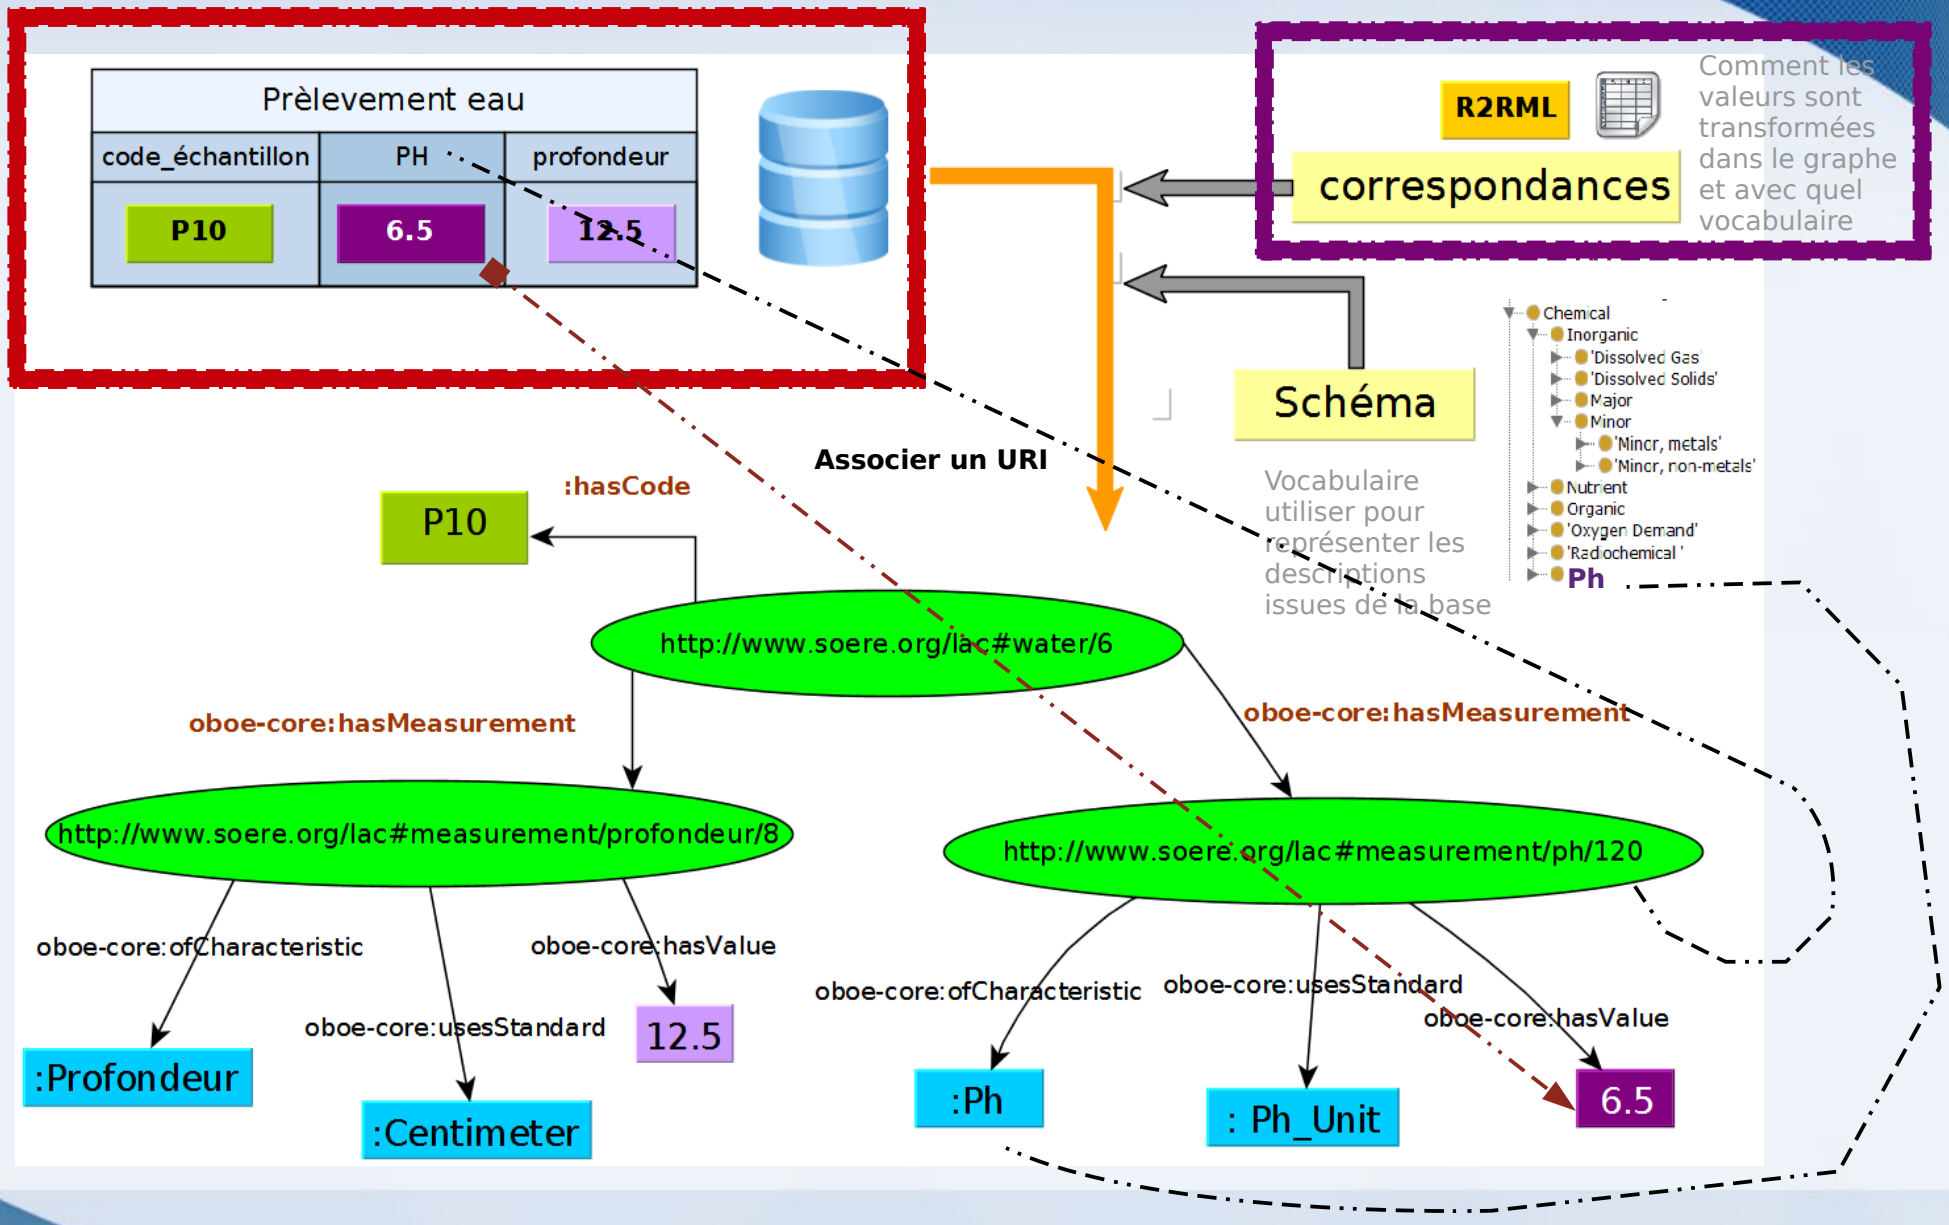

Avant un quelconque Dev

# Inventaire des outils sémantiques ( Sparql Endpoint )

( Phase de Publication Des Données )

## TripleStore

### * Sesame ✗

- Robustesse : **K.O**
- Scaling out : **K.O**
- Performance : **ERR**

### * Sol-RDF ✗

Apache Solr

- Robustesse : **OK**
- Scaling out : **OK**
- Performance : 👎

REST

### * BlazeGraph ✓

ZZ blazegraph™ by SYSTAP

- Robustesse : **OK**
- Scaling out : **OK ***
- Performance : **OK**

### * Corese ✓

Inria CORESE

- Robustesse : **OK**
- Scaling out : 👎
- Performance : **OK**

## Bases de données orientées Graphes

Structure plus généralisée
que celles des triplestores

# Inventaire des outils sémantiques ( Phase d'annotation )

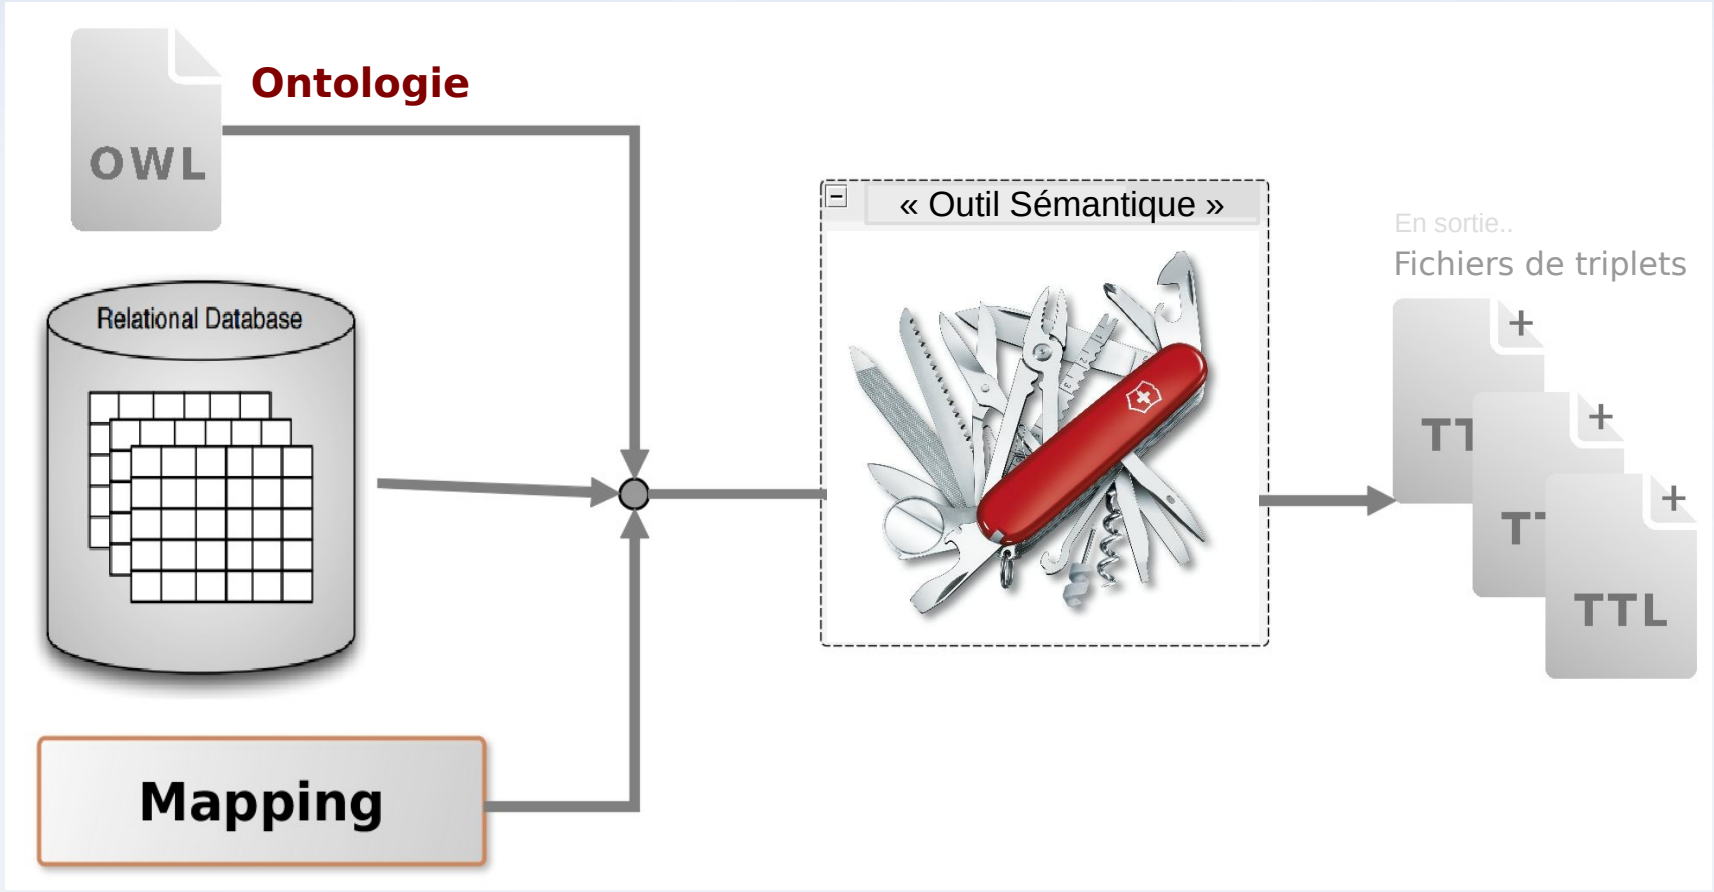


Comment les données relationnelles sont transformées en données sémantique...

# Inventaire des outils sémantiques ( Phase d'annotation )

## Outils de transformation à la volée

D2RQ

```
d2rq:column     "Conferences.Name"
d2rq:condition "PAPER.PDF IS NOT NULL"
d2rq:join "Papers.Conference => Conferences.ConfID"
```

- **Transformation à la volée des requêtes**
  **SPARQL ⇒ SQL ( Génération RDF à partir des BD-R )** ✓
- ~~Mapping non Intuitif ( Spécialement pour ceux qui ne manipulent que du SQL~~ ✗
- **~~Fail Last~~** Erreurs Mapping détectées au Runtime ✗
- ~~Pas d' Interface graphique~~ ! Projet Externe ~~( AuReli )~~ ✗

ontop

```
SELECT ID, VALUE FROM measurements
```

- **On-the-fly Ontology-based Data Access** ✓
- **Mapping Intuitif ( se base sur le SQL )** ✓
- ~~GUI intergée à Protegé~~ ✓
- ~~Support « uniquement » SPARQL 1.0~~ ✗

# Inventaire des outils sémantiques ( Phase d'annotation )

L'outil retenu : Ontop

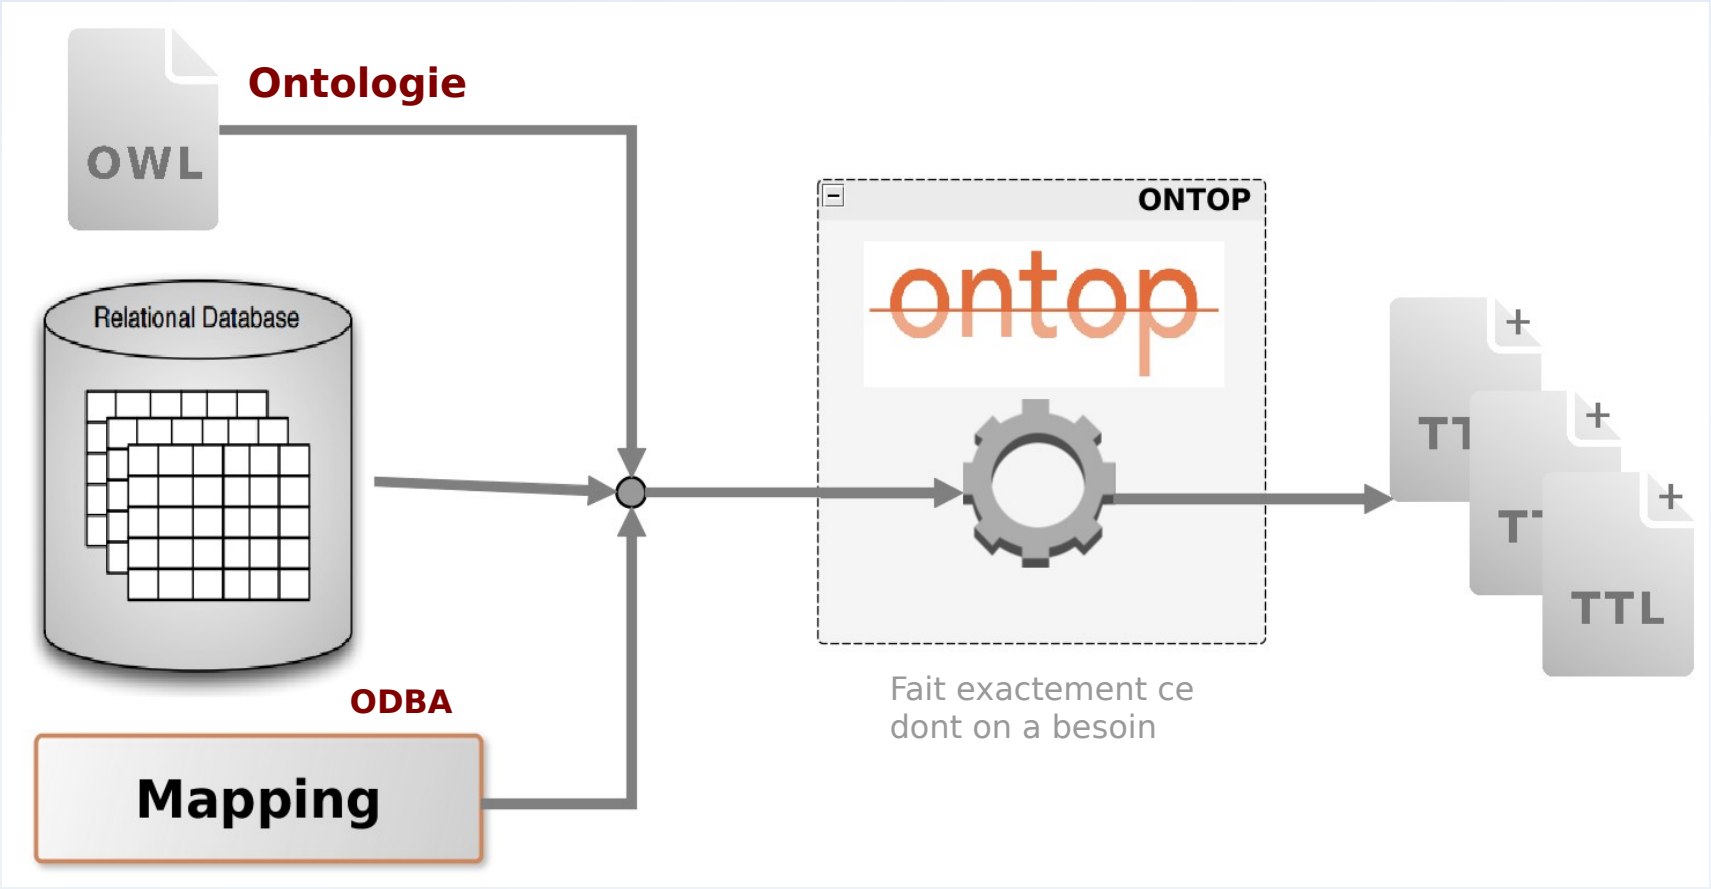


Fait exactement ce dont on a besoin

Comment les données relationnelles sont transformées en données sémantique...

Mais... ?

# Inventaire des outils sémantiques ( Phase d'annotation )

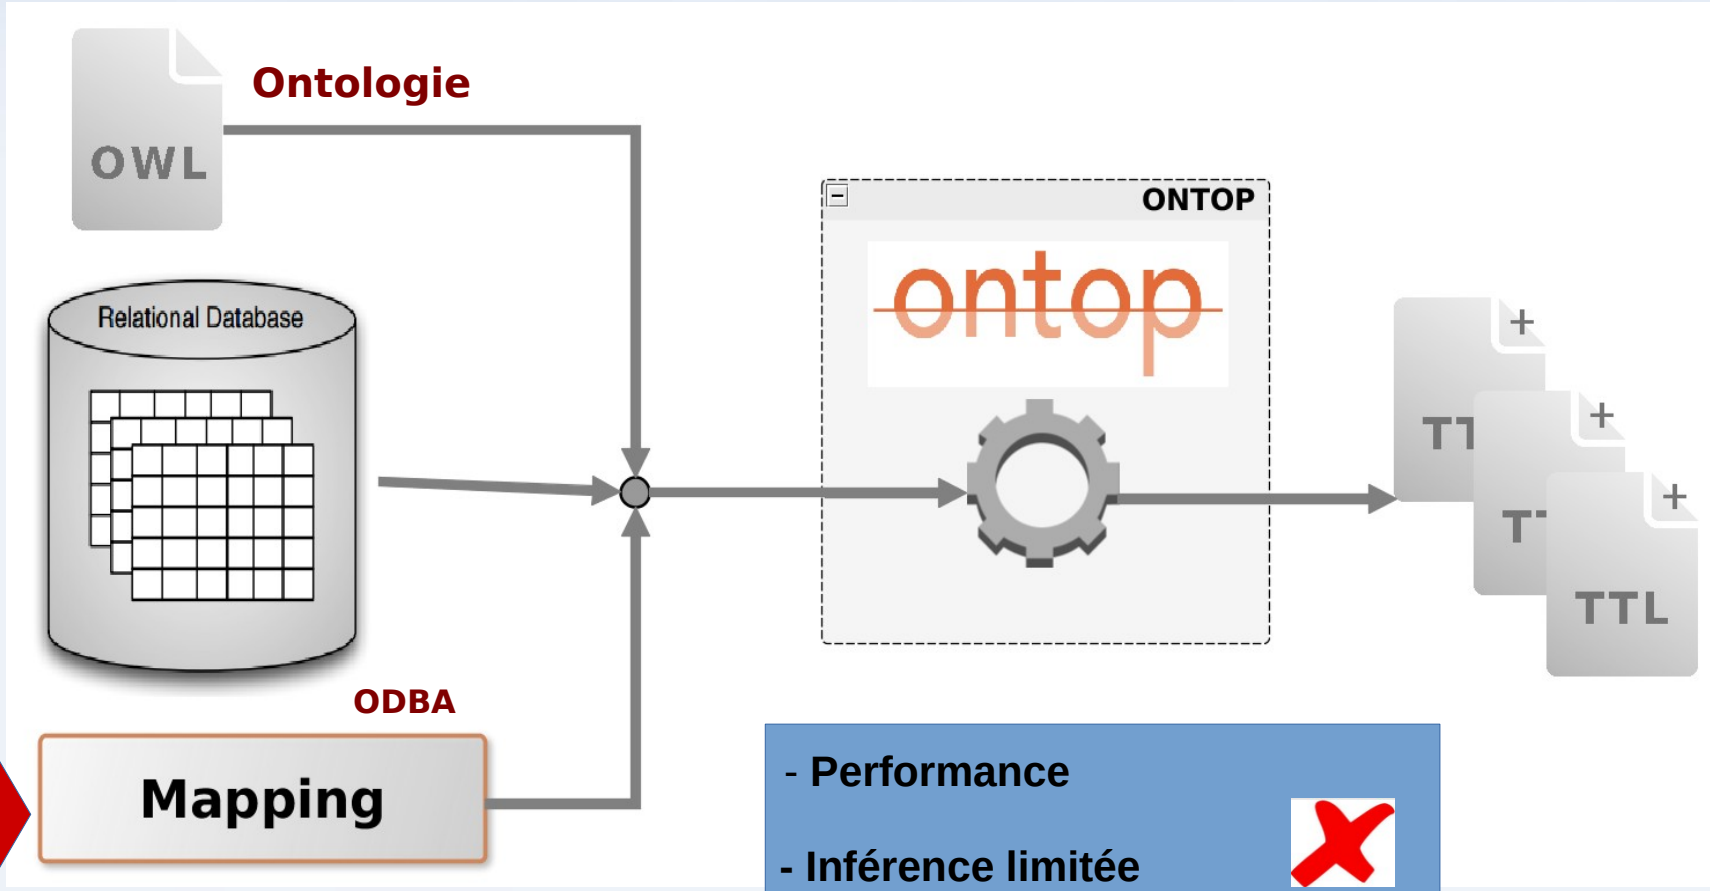


- Performance

- Inférence limitée
( Raisonneur QUEST )

**Limitations**

# Inventaire des outils sémantiques ( Limitations )

( Phase d'annotation )

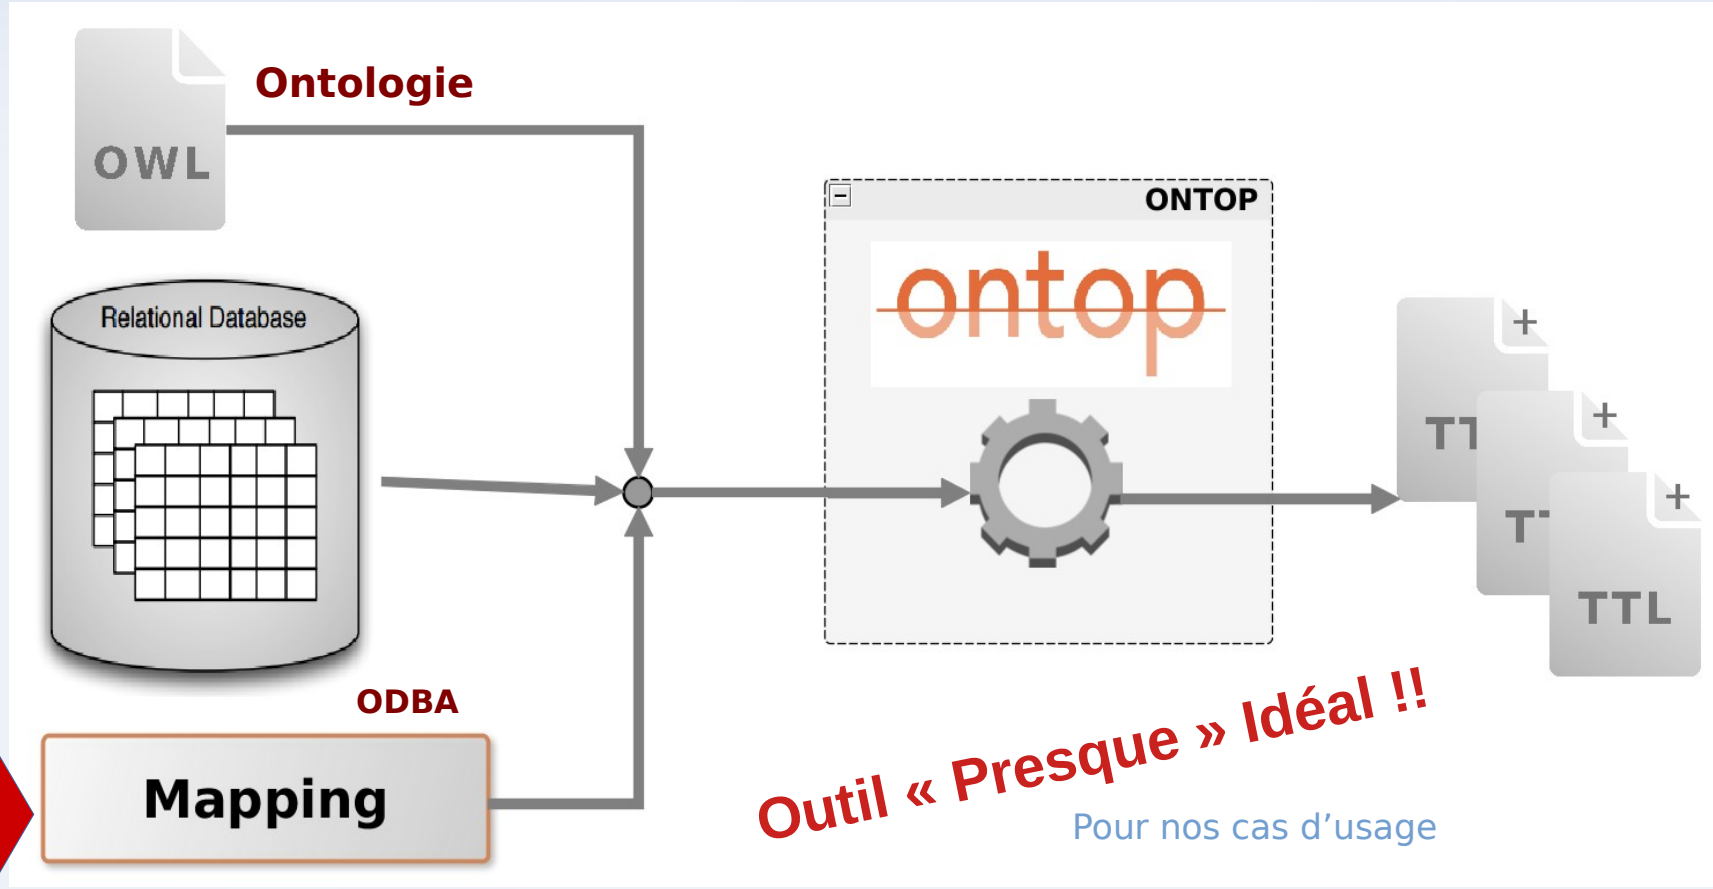


**Limitations**

# Automatisation

**Ontop - Protegé**

Ontop fourni une interface intergée à Protegé qui facilite la création des mapping.

Protegé :
outil open-source pour la création et l'édition des ontologies

**3 parties sont distinguées..**

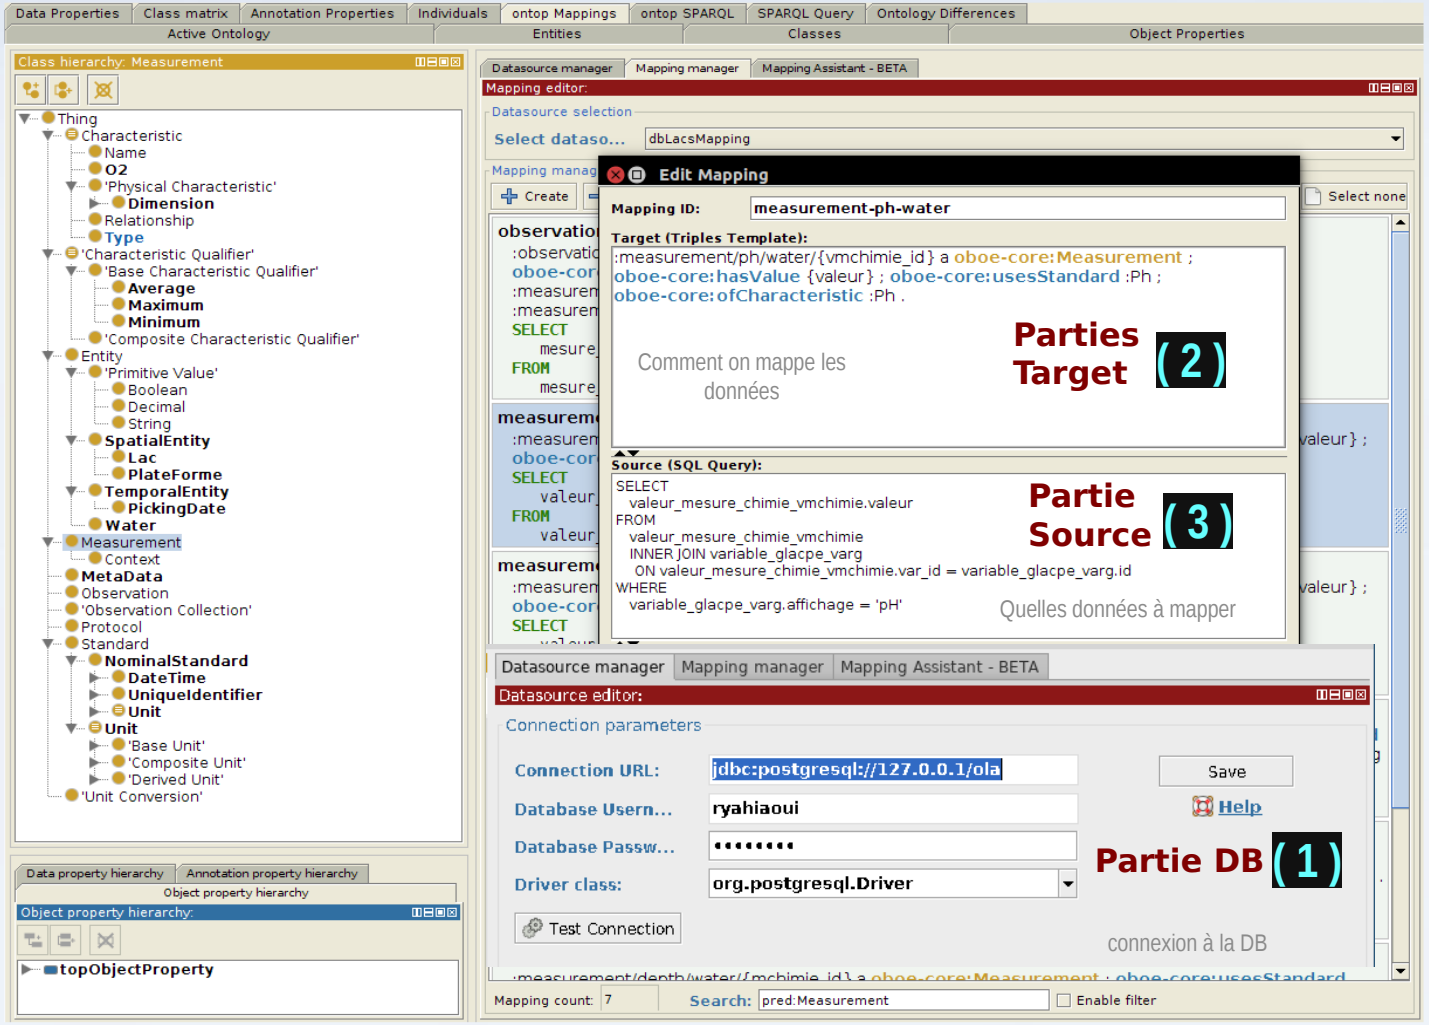


Créer les annotation à la main

# Automatisation

**Ontop - Protegé**

Ontop fourni une interface intergée à Protegé qui facilite la création des mapping.

Protegé :
outil open-source pour la création et l'édition des ontologies

**3 parties sont distinguées..**

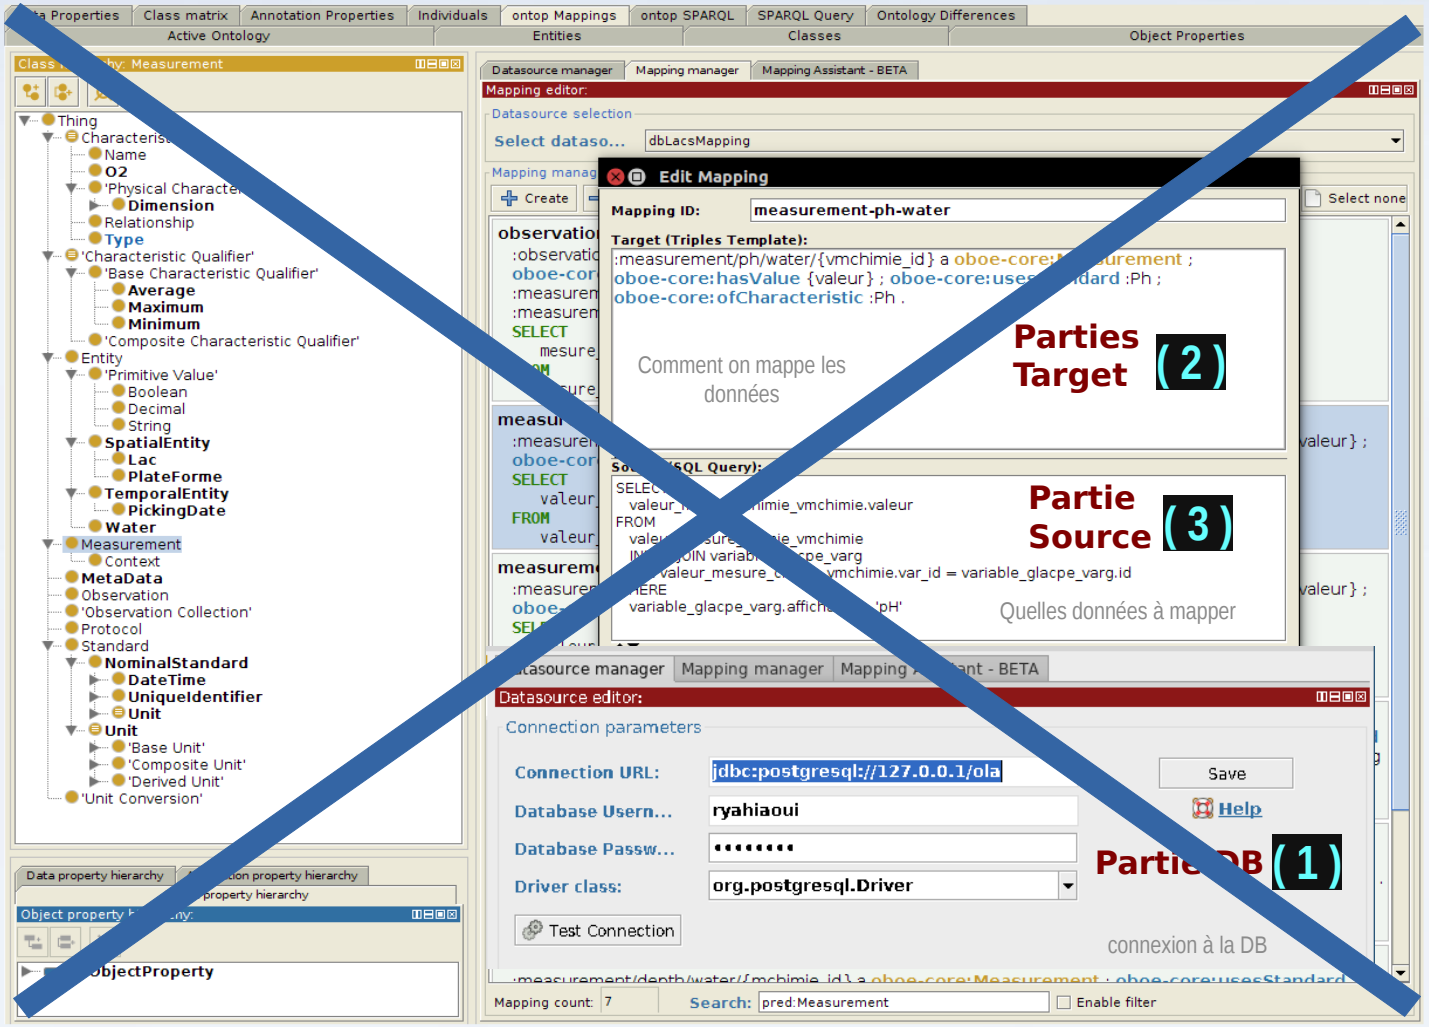


Créer les annotation à la main

# Automatisation

Sous le capot

## En coulisse... Ontop manipule des fichiers OBDA ( basé sur le langage R2RML )

( R2RML : recommandation du W3C pour faire du mapping RDB-to-RDF )

```
[PrefixDeclaration]                                    Interesting thing ..
rdf:  http://www.w3.org/1999/02/22-rdf-syntax-ns#      The 3 parts that was discussed previously
oboe-core: http://ecoinformatics.org/oboe/oboe.1.0/oboe-core.owl#
oboe-temporal: http://ecoinformatics.org/oboe/oboe.1.0/oboe-temporal.owl#
xsd: http://www.w3.org/2001/XMLSchema#
: http://www.anaee_france.fr/ontology/anaee-france_ontology#
oboe-standard: http://ecoinformatics.org/oboe/oboe.1.0/oboe-standards.owl#
oboe-characteristics: http://ecoinformatics.org/oboe/oboe.1.0/oboe-characteristics.owl#
oboe-spatial: http://ecoinformatics.org/oboe/oboe.1.0/oboe-spatial.owl#
oboe-standards:          http://ecoinformatics.org/oboe/oboe.1.0/oboe-standards.owl#
rdfs:           http://www.w3.org/2000/01/rdf-schema#

[SourceDeclaration]                                    how can we automate the generation of this kind of the mapping files
sourceUri       dbLacsMapping
connectionUrl   jdbc:postgresql://127.0.0.1/ola?sendBufferSize=5000
username        ryahiaoui
password        yahiaoui                    (1)  Informations de connexion à la BD
driverClass     org.postgresql.Driver

[MappingDeclaration] @collection [[

mappingId       (52) ola_characteristic_depthRelativeToSurface_min
target          :ola/characteristic/depthRelativeToSurface/min a :DepthRelativeToSurface
                oboe-core:hasQualifier :Minimum .                                    (2)
source          SELECT id from (values ('1')) s(id) ;   (3)   Comment on mappe les données

]]                                                     Quelle donnée à mapper
```

3 Parties importantes

*** Partie DB**

**(1)** **Informations d'accès à la BD Informations**

*** Partie Target**

**(2)** **Comment sont mappées les données**

Règle : Graphes sont composés de nœuds. Chaque nœud non terminal est identifié par un URI

**Partie Target = URI + Syntaxe Turtle**

*** Partie Source**

**(3)** **Quelles sont les données concernées par ce mapping**

Utilisation de requêtes SQL

# Automatisation

Exemple d'une Syntaxe Turtle **( Partie Target )**

```
Measurement(61)  a                :Measurement ;
                 :OfCharacteristic :Latitude
                 :usesStandard     :DecimalDegree
                 :hasValue         '10'
```

Représentation sous forme d'un Graphe

**Partie Target**

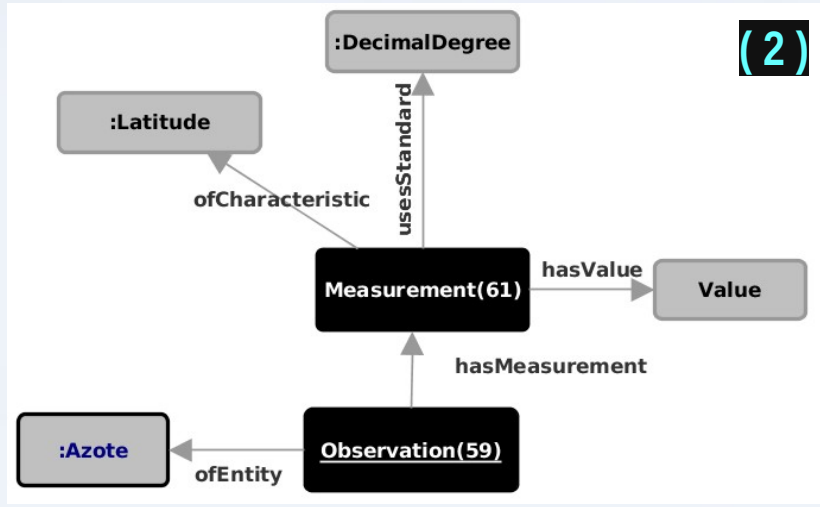


**Graphe de modélisation**

**⇒ À Partir d'un graphe de modélisation, on peut générer ( assez simplement ) la Partie Target ( décrite dans les fichiers ODBA )**

À condition de fournir un URI pour chaque nœud non terminal

Sachant que les graphes sont un outils simple et en mème temps puissants pour faire de la modélisation sémantique..

**Pourquoi ne pas générer les fichiers de mapping ( ODBA ) à partir de ces graphes de modélisation sémantique ??**

# Automatisation

**Partie Target**

Informations de connexion à la BD (1)

obda-sourceUri : dbLacsMapping

obda-connectionUrl : jdbc:postgresql://127.0.0.1/ola?sendBufferSize=5000

obda-username : ryahiaoui

obda-password : yahiaoui

obda-driverClass : org.postgresql.Driver

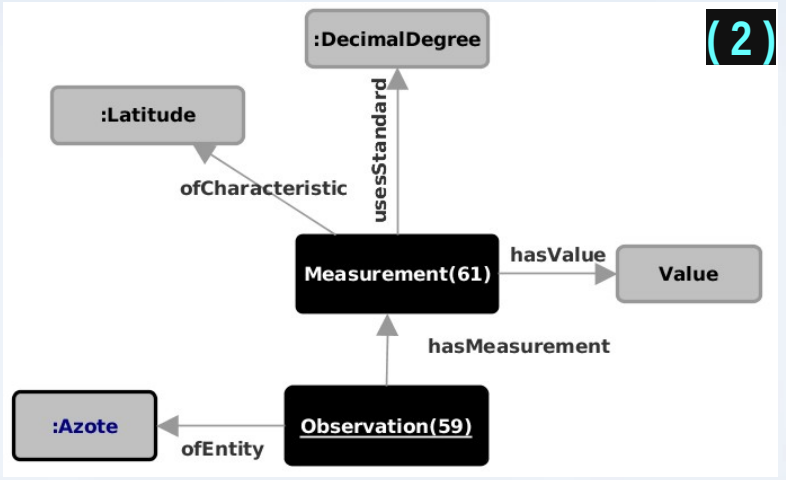


(61) ola/measurement/wayPoint/latitude/{site_id}/{platform_id}

YedGen : Outil de génération de fichiers ODBA à partir de graphes de modélisation

**Génération ODBA**

Concritized yedGen

Assigner une requête SQL pour chaque nœud non terminal

Query_(61) : SELECT pla.loc_id AS platform_id, site.id AS site_id, pla.latitude AS latitude
FROM
public.site_glacpe_sit site INNER JOIN public.plateforme_pla pla ON site.id = pla.id (3)

**Partie Source**

**C'est ainsi qu'à été résolu le problème de l'automatisation..**

Automatisation

# Généricité

L'idée derrière cette généricité est d'utiliser un mème graphe pour modéliser plusieurs variables ( renseignées potentiellement dans un fichier CVS )

Cette généricité concerne le fonctionnement de l'outil yedGen

**Pourquoi ? Parce que ces Variables ont la mème structure dans la BD**

Au lieu d'avoir un graphe par variable, on aura donc un **graphe type** ( désigné pour plusieurs variables ), et à partir de ce graphe type, générer un fichier de mapping ( ODBA ) par variable

**Graphe Type =**
**Un graphe pour plusieurs variables**

**Description d'un fichier CSV de variables sémantiques**

| | AnaEE Standar | Entity | Context | .. |
|---|---|---|---|---|
| 1 | cumulative rainfall | cumulative rain | | .. |
| 2 | air carbon dioxide | carbon dioxyde | atmosphere, | .. |
| 3 | atmospheric air sta | air | atmosphere | .. |

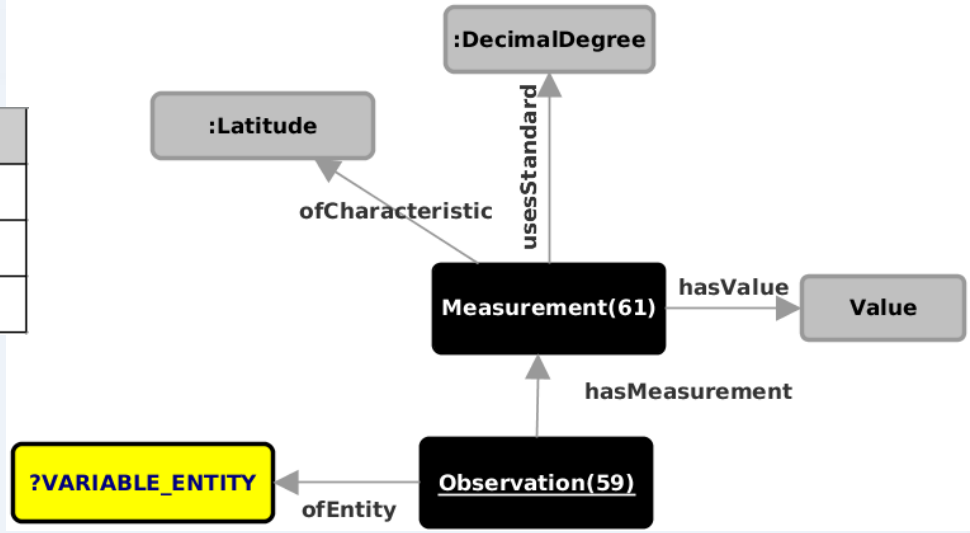


Appliquer sur la variable **VARIABLE_ENTITY** chaque valeur de la colonne **Entity du fichier CSV.** Ce qui nous donne ...

Automatisation

# Généricité

**Description d'un fichier CSV de variables sémantiques**

| | AnaEE Standar | Entity | Context | .. |
|---|---|---|---|---|
| 1 | cumulative rainfall | cumulative rain | | .. |
| 2 | air carbon dioxide | carbon dioxyde | atmosphere | .. |
| 3 | atmospheric air sta | air | atmosphere | .. |

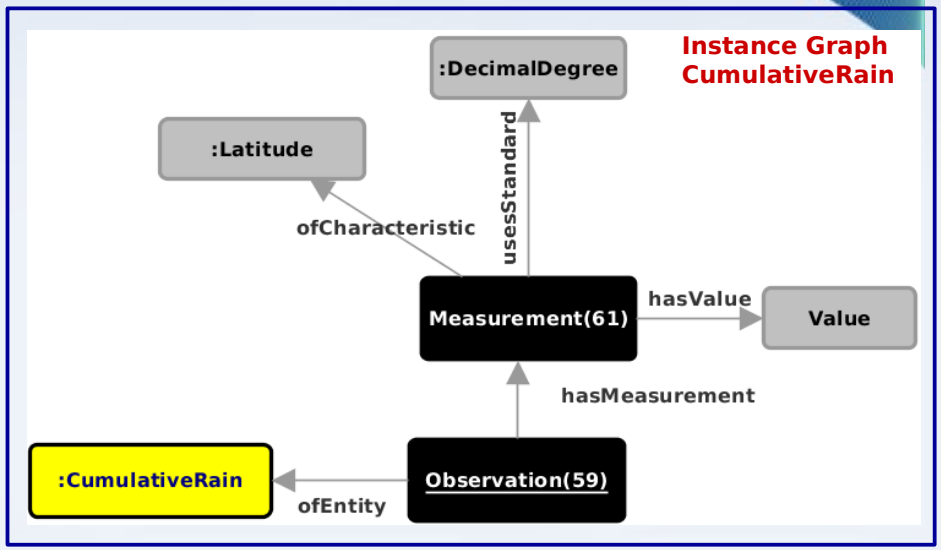

Automatisation

# Généricité

**Description d'un fichier CSV de variables sémantiques**

| | AnaEE Standar | Entity | Context | .. |
|---|---|---|---|---|
| 1 | cumulative rainfall | cumulative rain | | .. |
| 2 | air carbon dioxide | carbon dioxyde | atmosphere | .. |
| 3 | atmospheric air sta | air | atmosphere | .. |

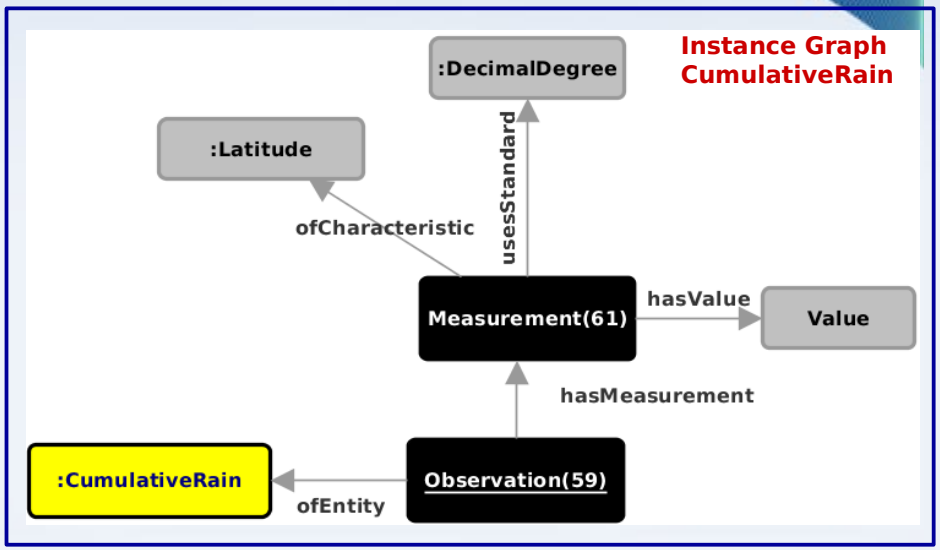


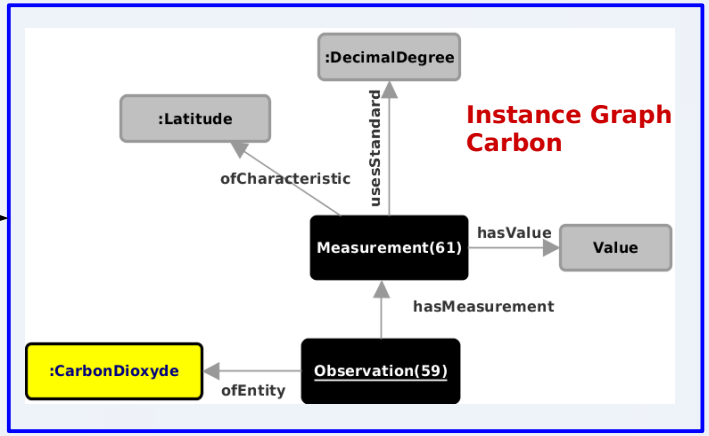

Automatisation

# Généricité

**Description d'un fichier CSV de variables sémantiques**

| | AnaEE Standar | Entity | Context | .. |
|---|---|---|---|---|
| 1 | cumulative rainfall | cumulative rain | | .. |
| 2 | air carbon dioxide | carbon dioxyde | atmosphere | .. |
| 3 | atmospheric air sta | air | atmosphere | .. |

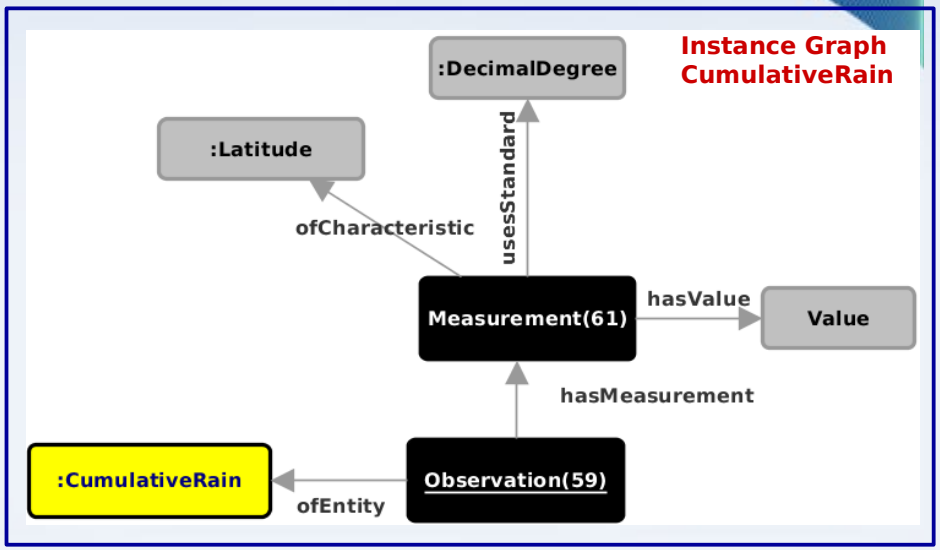


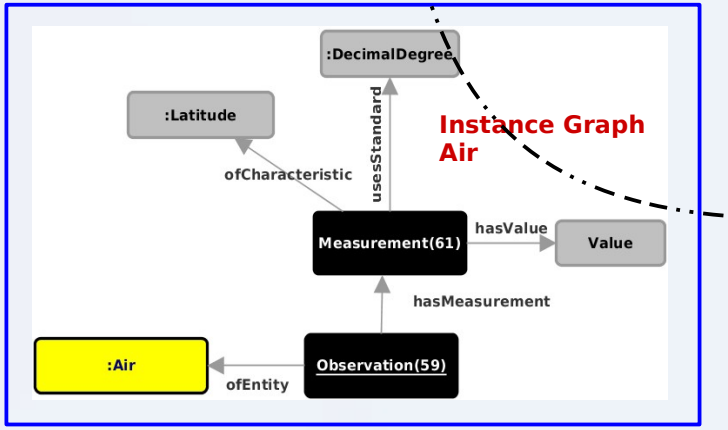


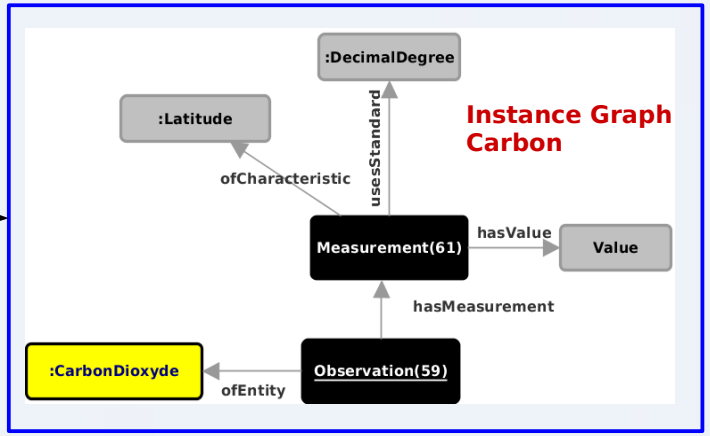

Automatisation

# Généricité

**Description d'un fichier CSV de variables sémantiques**

| | AnaEE Standar | Entity | Context | .. |
|---|---|---|---|---|
| 1 | cumulative rainfall | cumulative rain | | .. |
| 2 | air carbon dioxide | carbon dioxyde | atmosphere | .. |
| 3 | atmospheric air sta | air | atmosphere | .. |

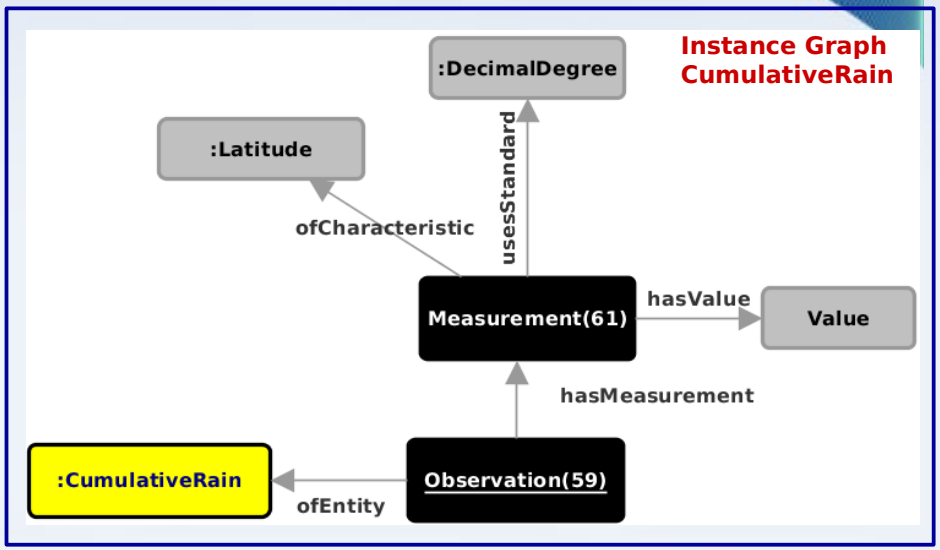


**Le mème process est répété pour chaque ligne du CSV..**

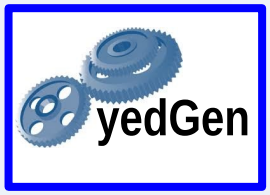


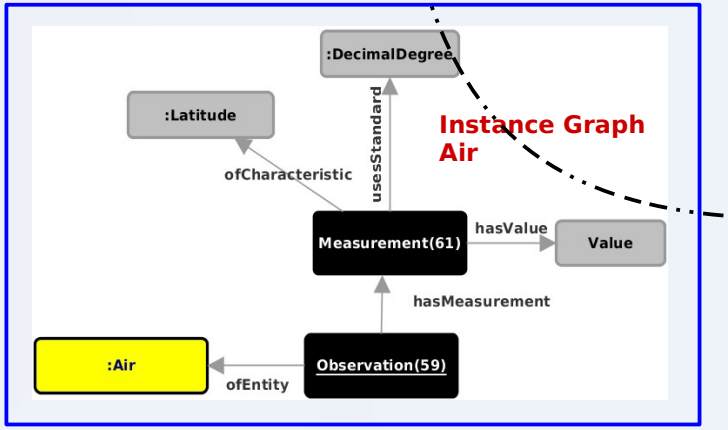


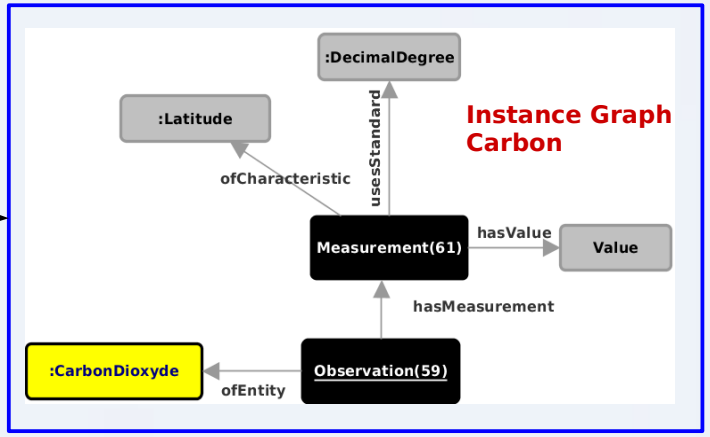


C'est ainsi qu'à été approché la problématique de la généricité

## Gros Fichiers / Grosse Bases de données

Il arrive parfois que le volume de données traité par **ONTOP** et **BlazeGraph** dépasse la capacité mémoire de la machine, dans ce cas, on est confronté à des **Outofmemoryerrors**

Solution : **Volume data Partitioning** → Traitement des données par chunk ( LIMIT/OFFSET )

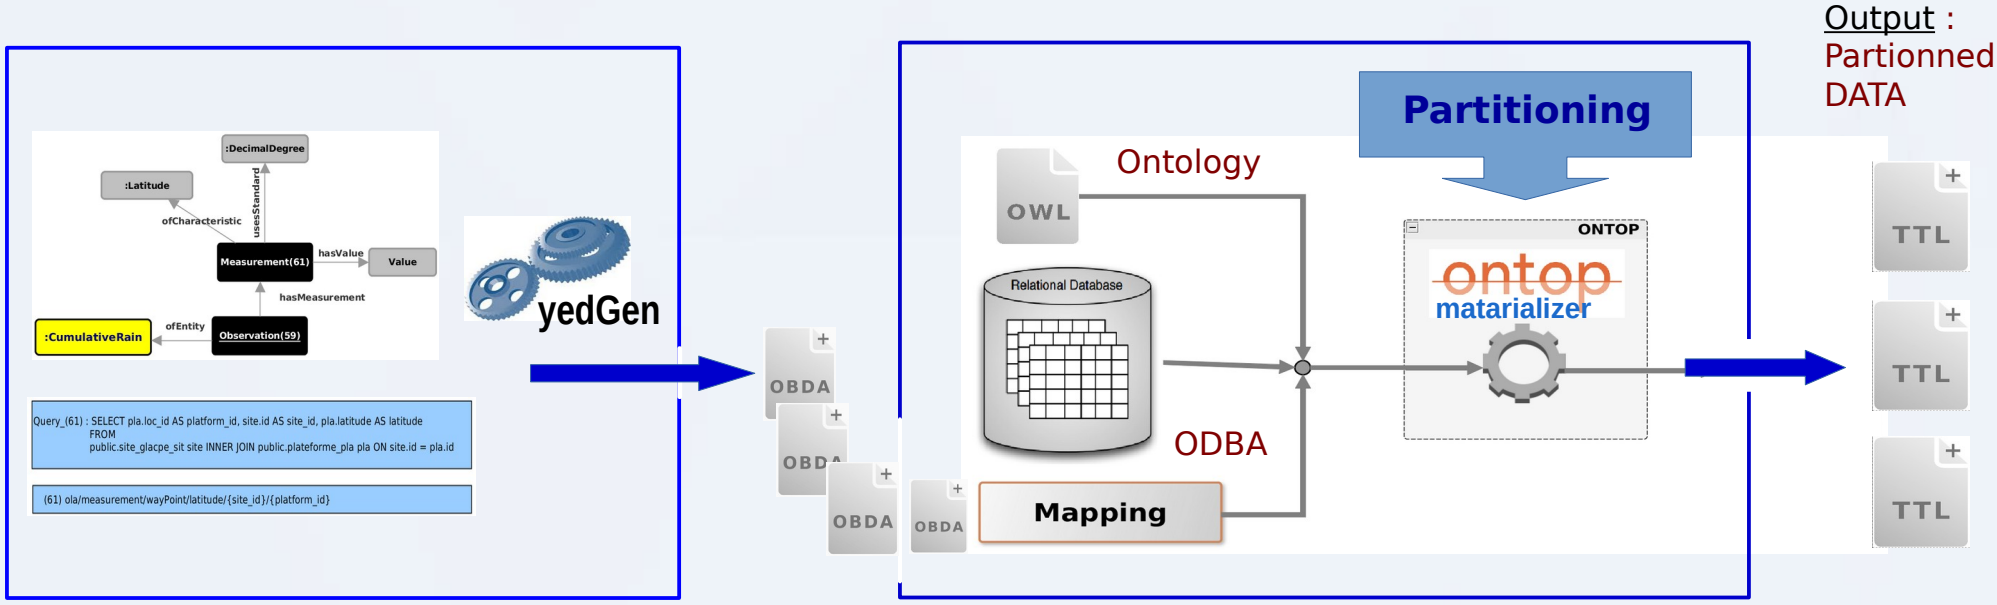


Output : Partionned DATA

→ Traiter un volume « infini » de données

# Filtre sur les données

Pour certains use cases, on a besoin de n'extraire que la donnée dont l'utilisateur a besoin

Plus vous filtrez les données, moins vous en avez, plus vous êtes performant

Solution : **Logical data partionning**

**Exemple** : Générer des données spécifiques à une **variable** particulière, pour un **site** particulier et un interval **d'années** particuliers

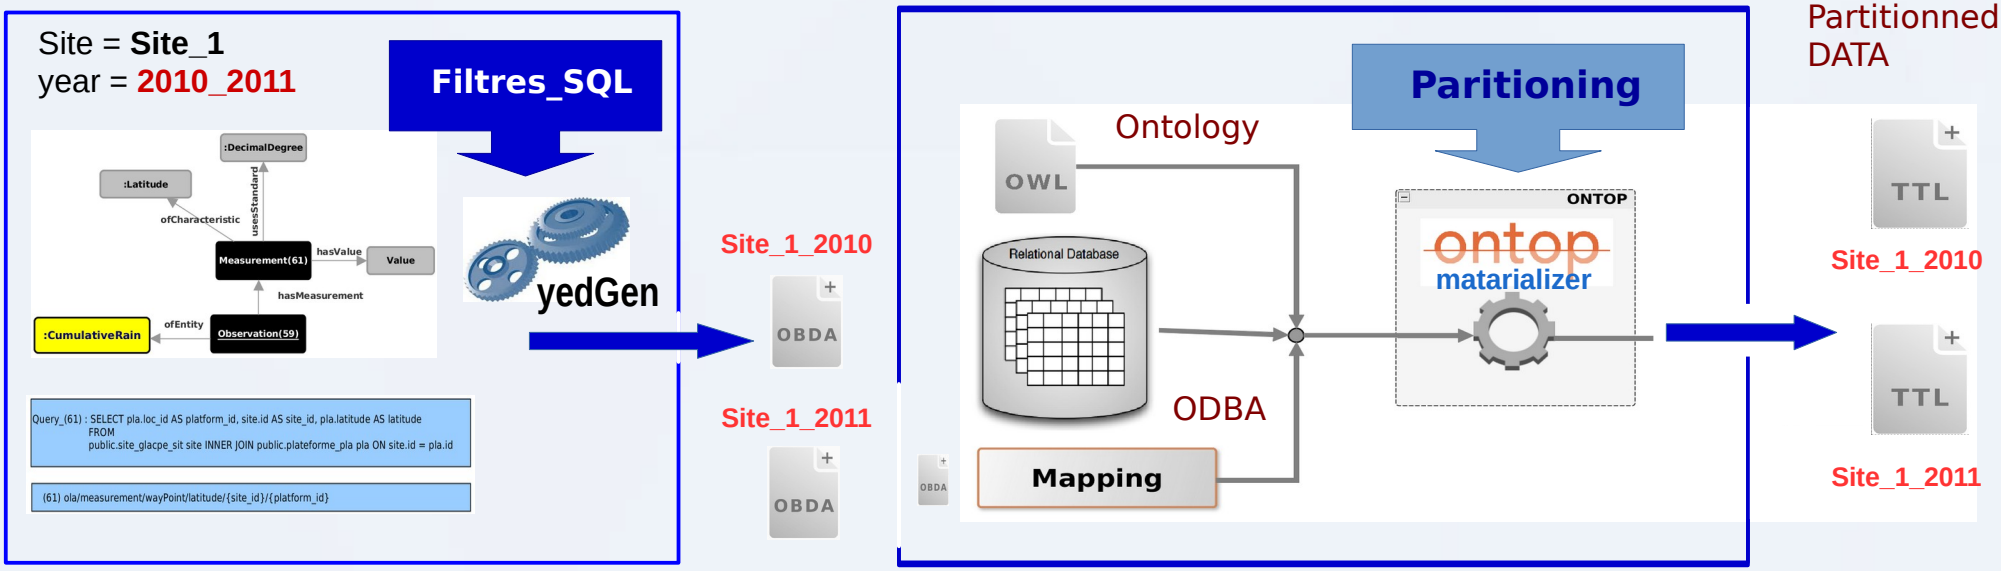


Output : Logical Partitionned DATA

**Remarque** : Volume data partitioning & Logical data partitioning peuvent être **combinés**

# L’approche Automatisation



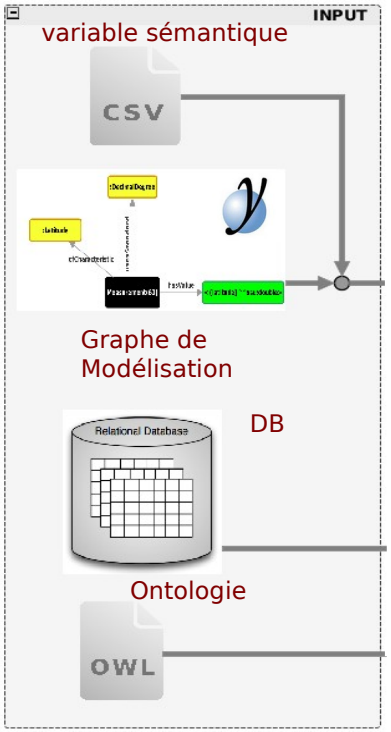


Pipeline

# L’approche Automatisation



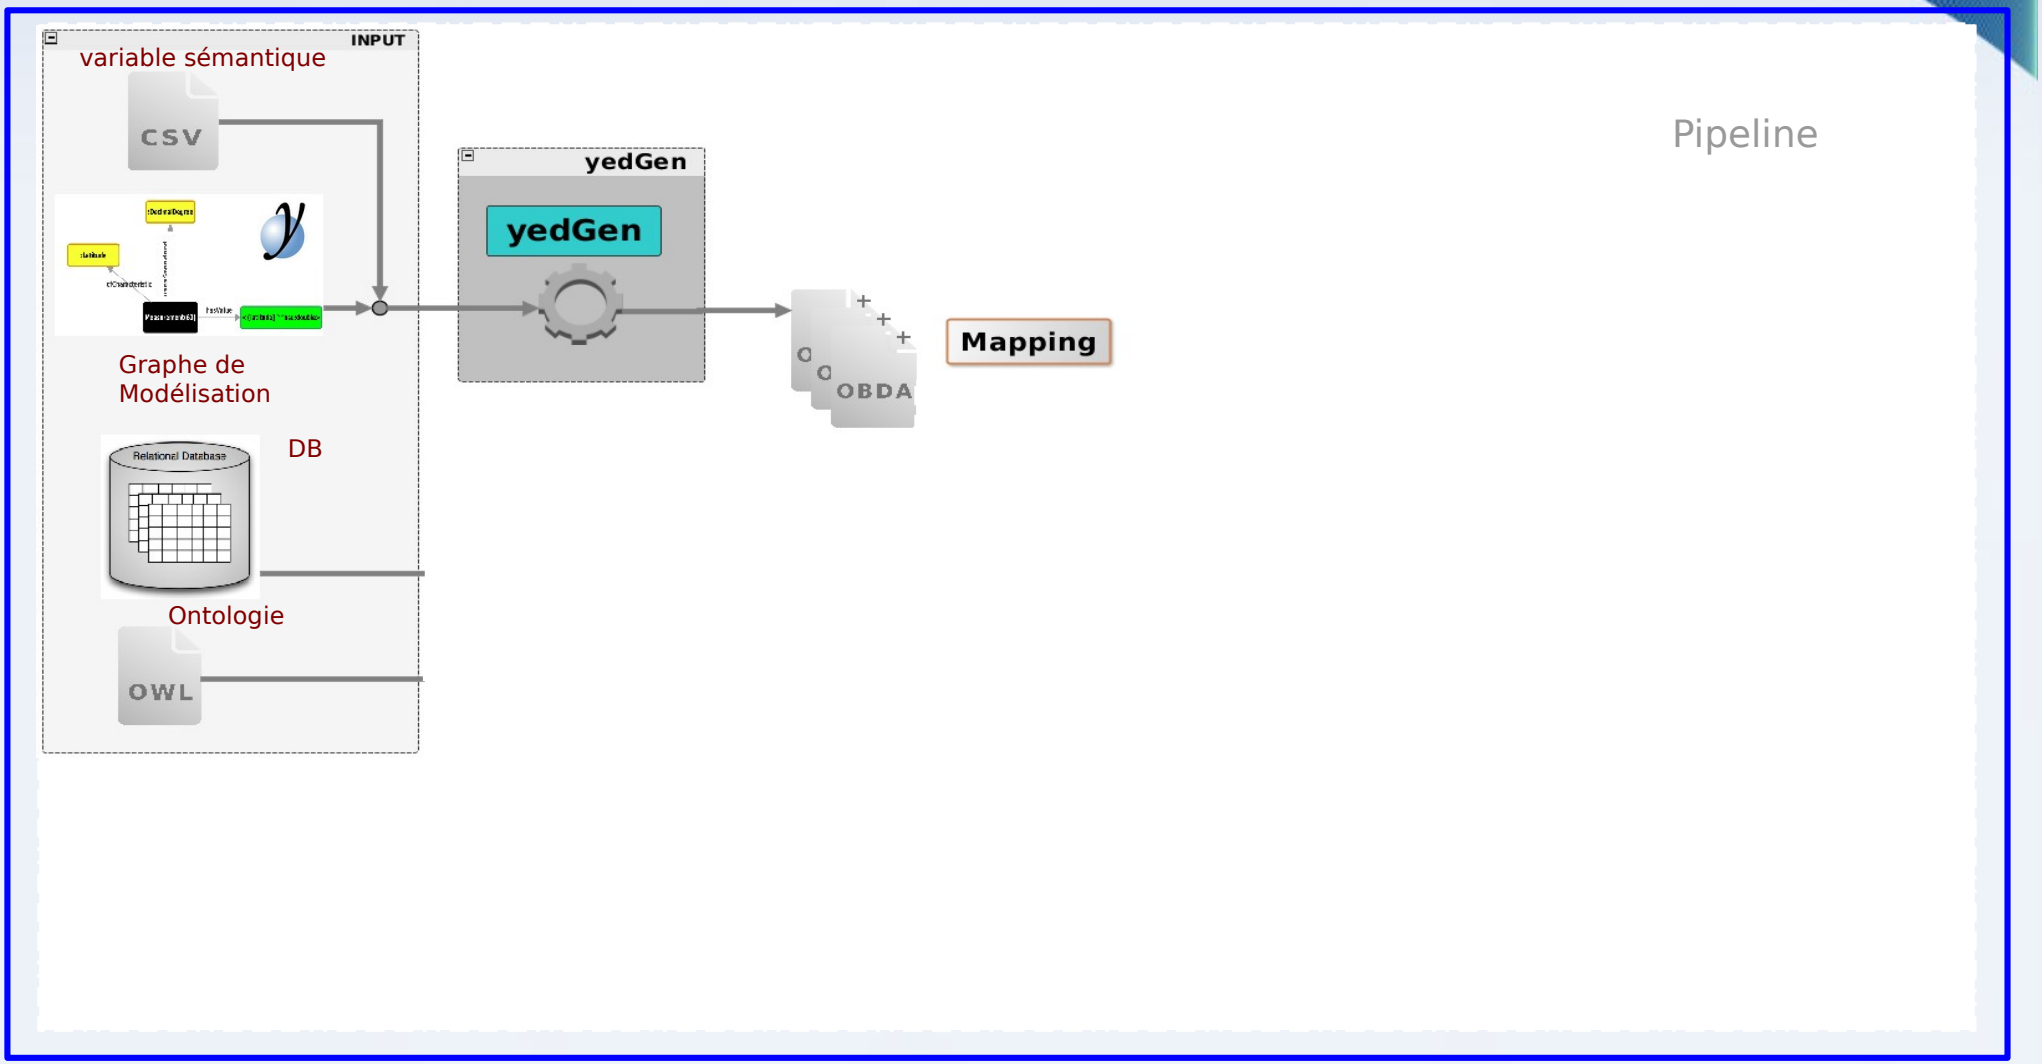

# L’approche Automatisation



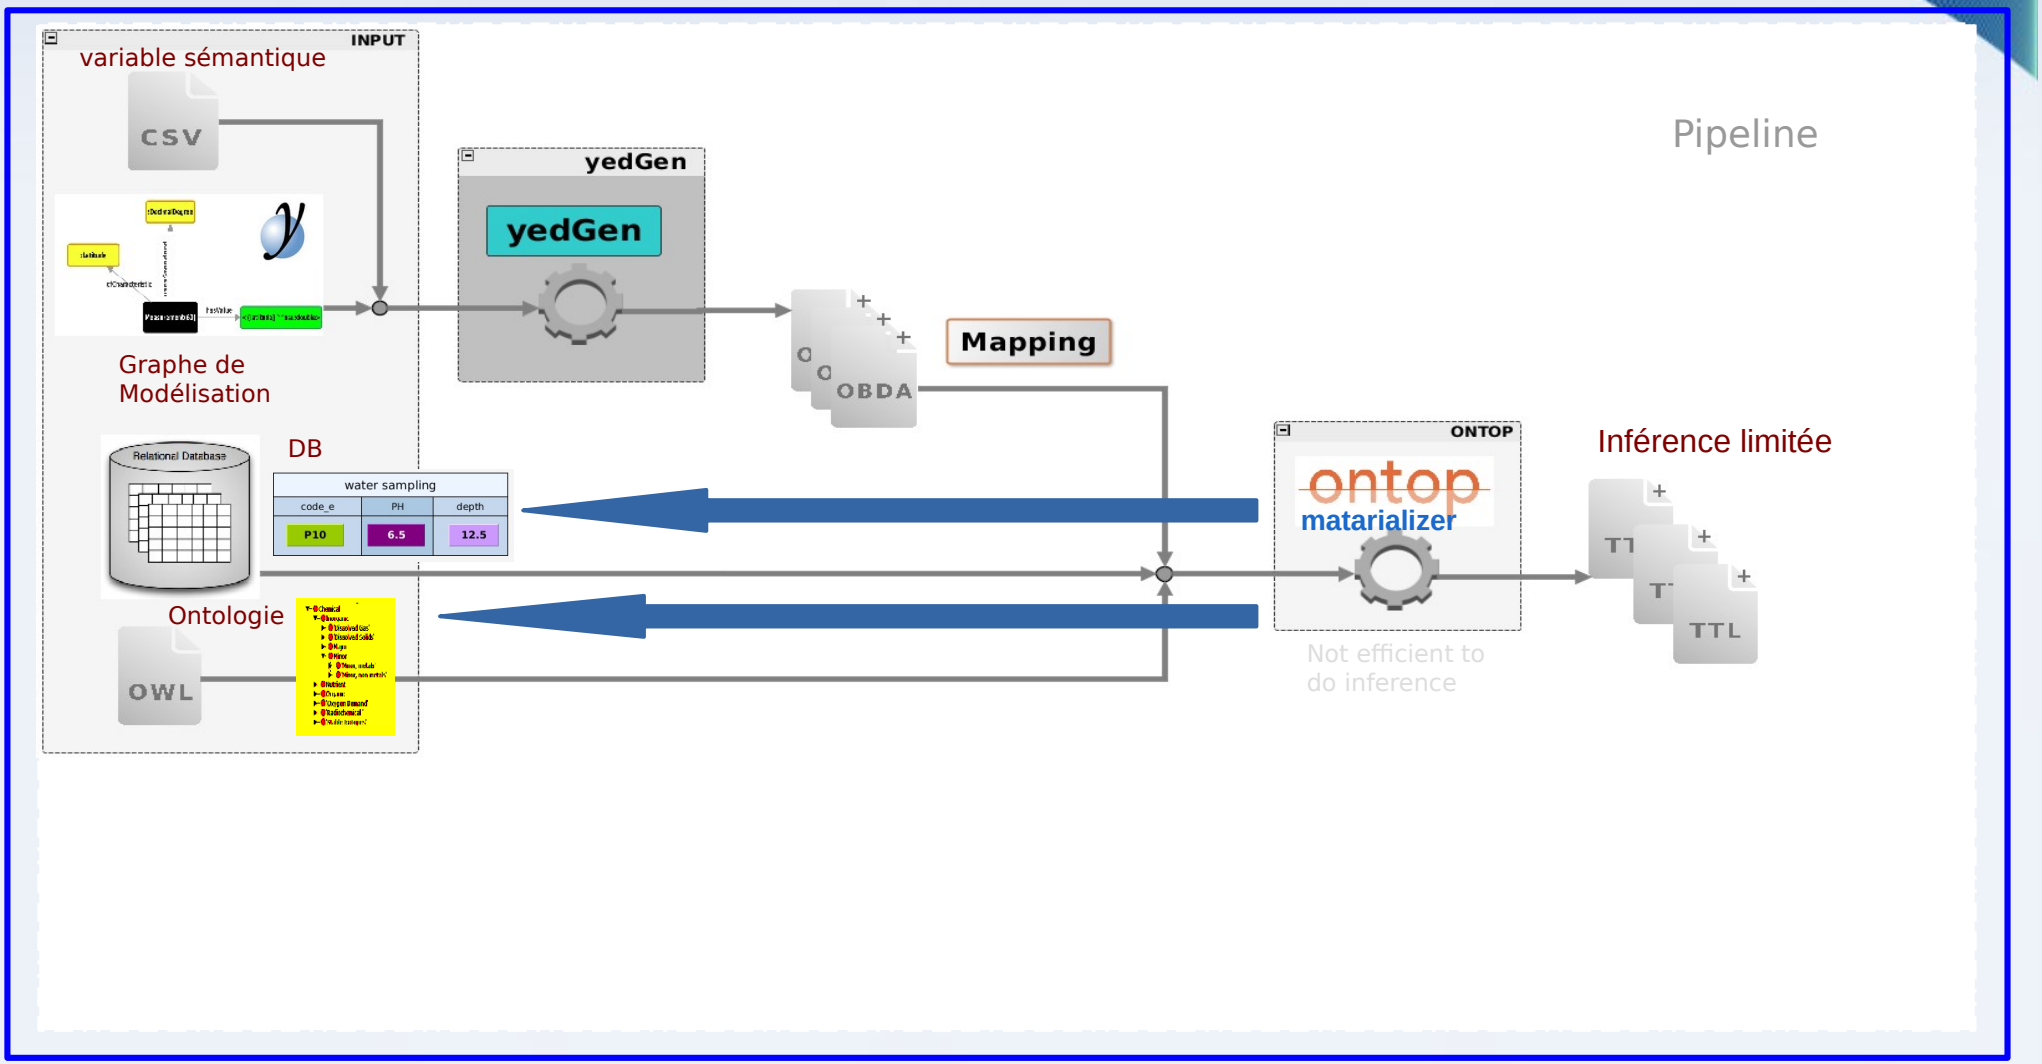

# L’approche Automatisation



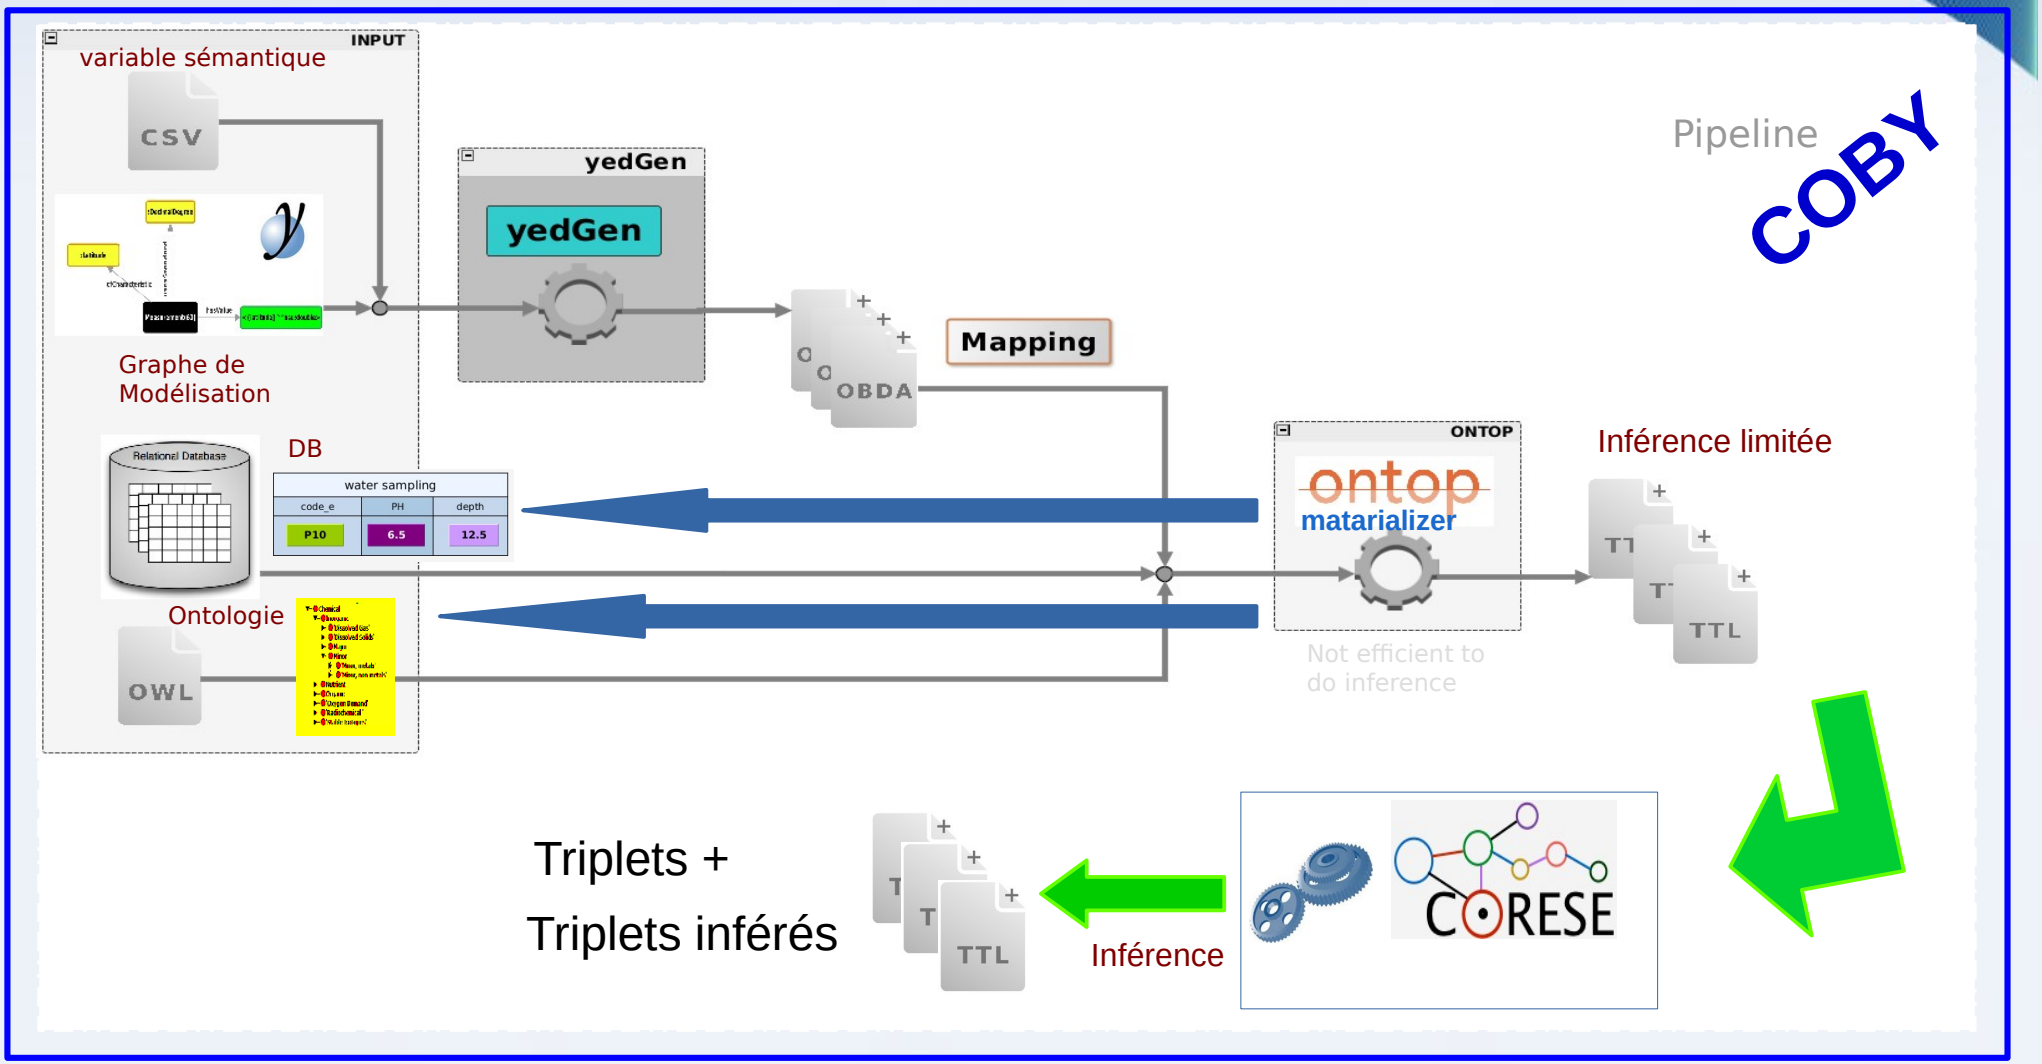

# USE CASES



## 1 – Données de synthèse ( sémantiques ) pour le portail Anaee-F

Use Case 1

Pipeline Side

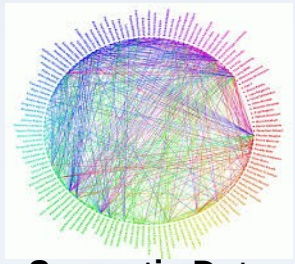

**Semantic Data**

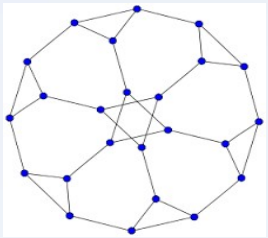

**Summarized Data**

Portal side

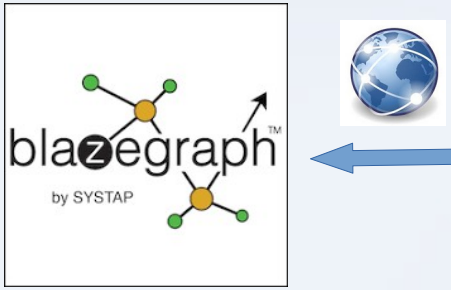


**SPARQL endPoint**

Semantic Portal

**Objectif :** Production de données de synthèse sémantique par le pipeline d'annotation, et publication de ces dernières sur un Sparql-Endpoint directement accessible par le Portail AnaEE-F

---

## 2 - Production de fichiers netCDF

Use Case 2

**Objectif :** Production de données sémantiques filtrées ( au format TTL ), qui seront utilisées pour produire des fichiers au format **netCDF**

## Métriques & Plus-value

**- yedGen : Génération instantanée des fichiers de mapping ( ODBA ) à partir des graphes de modélisation**

**⇒ Passage instantané : Modélisation → Annotation**

**- Image Docker pré-configurée du pipeline + Déployable en un clique**

**- Généricité**

**- Métriques :**

**( Machine test : I7 / 8 Cores / 5 Go Heap )**

| | | | | |
|---|---|---|---|---|
| * **Génération** | ( Ontop ) | ~ | **700.000** | triplets / mn |
| * **Inférence** | ( Moteur Corese ) | ~ | **2.600.000** | triplets / mn |
| * **Chargement** | ( BlazeGraph ) | ~ | **3.000.000** | triplets / mn |

## ** À l'échelle des SOERE :

Modélisation de nouveaux types de données

⇒ Consiste à la création de nouveaux modèles d'annotations pour les variables stockées en base de données en utilisant l'outil **Yed Graph Editor** pour les graphes

## ** À l'échelle du  Pipeline :

**- Augmenter les perfomances en introduisant du traitement  distribué ⇒**

**[ Technologie Docker** ] → Un Fichier ODBA  ( Mapping ) par conteneur Docker )**

**- Développement d'un PSL ( Pipeline Specific Langage ) ⇒**

**Simplification d'écriture des Orchestrateurs ( use cases – écrit actuellement en Bash ! )**

- Autres pistes : **Apache RYA** !

**Docker** : Technologie de « conteneurisation »

# MERCI DE VOTRE ATTENTION